

Západočeská univerzita v Plzni
Fakulta aplikovaných věd
Katedra kybernetiky



SEMESTRÁLNÍ PRÁCE Č. 2

TEORIE ODHADU A ZPRACOVÁNÍ SIGNÁLŮ
ZKRATKA KATEDRY/ZKRATKA PŘEDMĚTU (KKY/TOD)

Jan Burian
16. listopadu 2022

Obsah

1	Zadání	3
2	Vypracování	4
2.1	Teoretické úkoly	4
2.1.1	Úkol (i)	4
2.1.2	Úkol (ii)	9
2.1.3	Úkol (iii)	11
2.2	Simulační úkoly	13
2.2.1	Úkol (i)	13
3	Závěr	21
A	Zdrojový kód z Matlabu	22

Optimální odhad náhodné proměnné

Zadání semestrální práce č. 2

Uvažujme objekt, který se pohybuje po přímce s náhodným zrychlením, zatímco je s konstantní periodou T měřena jeho poloha. Cílem je na základě měření a modelu systému odhadnout neznámou počáteční polohu a rychlost objektu, se známou apriorní informací ve formě náhodné veličiny. V diskrétním případě můžeme uvažovat lineární dynamický systém s popisem

$$\mathbf{x}_{k+1} = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} \mathbf{x}_k + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N} \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \frac{1}{10} \begin{bmatrix} \frac{T^3}{3} & \frac{T^2}{2} \\ \frac{T^2}{2} & T \end{bmatrix} \right), \quad \mathbf{x}_0 \sim \mathcal{N} \left(\begin{bmatrix} \bar{x}_0^{\text{poloha}} \\ \bar{x}_0^{\text{rychlost}} \end{bmatrix}, \begin{bmatrix} 1 & 1 \\ 1 & 4 \end{bmatrix} \right),$$

$$z_k = \begin{bmatrix} 1 & 0 \end{bmatrix} \mathbf{x}_k + v_k, \quad v_k \sim \mathcal{N}(0, 1),$$

kde vzorkovací perioda je $T = 1$, a procesy $[\mathbf{w}_k]_{k=1}^{+\infty}$ a $[v_k]_{k=1}^{+\infty}$ jsou vzájemně nezávislé bílé šумы, nezávislé na počátečním stavu \mathbf{x}_0 . Stav \mathbf{x}_0 zvolte libovolně.

Teoretické úkoly: Odhad ve smyslu ML a LMSE z prvních několika měření.

- (i) Pro porovnání nejprve apriorní informaci ignorujte a navrhněte odhad $\hat{\mathbf{x}}_0$ počátečního stavu \mathbf{x}_0 ve smyslu maximální věrohodnosti při použití měření $\mathbf{z} = [z_0, z_1]^T$. Dále apriorní informaci v potaz vezměte, a určete nejlepší lineární odhad ve smyslu střední kvadratické chyby při použití měření A) z_0 B) z_1 a C) z . Co o veličině \mathbf{x}_0 říká konkrétně zadaná apriorní informace a jak se projev v rovnicích?

Dále vyjádřete kovarianční matice chyb odhadů pro všechny případy. Všimněte si, že kovarianční matice odhadu a chyby odhadu se v případě odhadu náhodné veličiny liší.

- (ii) Pozorujte, co se může stát, když estimátor bude navržen za špatné znalosti parametrů systému. Pro jednoduchost uvažujte jen LMSE případ C). Sestrojte odhady, kde při návrhu uvažujete hodnoty parametrů Ca) $R = \frac{1}{4}$, Cb) $R = 4$ a Cc) $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$, ale ve skutečnosti jsou všechny parametry stejné jako v předchozím bodě. Dopočítejte kovarianční matice chyb poskytované algoritmem odhadu, tj. založené na nesprávných hodnotách parametrů, a skutečné kovarianční matice chyb odhadů. Diskutujte strannost těchto odhadů.
- (iii) Pro všechny odhady vykreslete $3\text{-}\sigma$ elipsy odpovídající chybám odhadů. Pro odhad s kovarianční maticí chyby odhadu \mathbf{P} uvažujte křivku $\{\mathbf{x} \in \mathbb{R}^2 : (\mathbf{x} - \mathbf{b})^T \mathbf{P}^{-1} (\mathbf{x} - \mathbf{b}) = 9\}$, kde $\mathbf{b} = E(\mathbf{x}_0 - \hat{\mathbf{x}}_0)$. Pro odhady Ca), Cb), Cc) dále vykreslete elipsy pro matice poskytované algoritmem odhadu a diskutujte vztahy mezi skutečnými a poskytovanými kovariačními maticemi chyb odhadů.

Simulační úkoly: Simulační ověření teoretických výsledků.

Pomocí funkce `randn` vygenerujte 1000 simulací vektoru $[\mathbf{x}_0^T, \mathbf{z}^T]^T$ a pro každý nasimulovaný vektor dopočítejte realizace odhadů $\hat{\mathbf{x}}_0$ a chyb odhadů $\tilde{\mathbf{x}}_0 = \mathbf{x}_0 - \hat{\mathbf{x}}_0$.

- (i) Odhadněte hustoty *chyb* jednotlivých odhadů *polohy* pomocí normalizovaných histogramů a porovnejte je mezi sebou. Dále pomocí techniky přiřazení momentů proložte normalizované histogramy gaussovskými hustotami. Proložené hustoty porovnejte s teoretickými.

2 Vypracování

Semestrální práce byla z velké části řešena v programovém prostředí Matlab.

2.1 Teoretické úkoly

2.1.1 Úkol (i)

Prvním bodem tohoto úkolu je navrhnout odhad $\hat{\mathbf{x}}_0$ počátečního stavu $\mathbf{x}_0 \sim \mathcal{N}\left(\begin{bmatrix} \bar{x}_0^{\text{poloha}} \\ \bar{x}_0^{\text{rychlost}} \end{bmatrix}, \begin{bmatrix} 1 & 1 \\ 1 & 4 \end{bmatrix}\right)$

ve smyslu maximální věrohodnosti při použití měření $\mathbf{z} = [z_0, z_1]^T$. Nejprve byl zadaný systém přepsán do následujícího tvaru:

$$\mathbf{x}_{k+1} = \mathbf{F}\mathbf{x}_k + \mathbf{G}\mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}), \quad (1)$$

$$\mathbf{z}_k = \mathbf{H}\mathbf{x}_k + \mathbf{v}_k, \quad \mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}), \quad (2)$$

kde $\mathbf{F} = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}$, $\mathbf{G} = I$, $\mathbf{Q} = \frac{1}{10} \begin{bmatrix} \frac{T^3}{3} & \frac{T^2}{2} \\ \frac{T^2}{2} & T \end{bmatrix}$, $\mathbf{H} = [1 \ 0]$ a $\mathbf{R} = 1$.

Ze zadání je dále známo, že náhodné veličiny \mathbf{w}_k a \mathbf{v}_k jsou vzájemně nezávislé bílé šumy $\forall k \in \mathbb{N}$.

Následně již bylo možné začít sestavovat trajektorii stavu a měření.

$$\begin{bmatrix} \mathbf{x}_0 \\ \mathbf{x}_1 \end{bmatrix} = \begin{bmatrix} \mathbf{x}_0 \\ \mathbf{F}\mathbf{x}_0 + \mathbf{w}_0 \end{bmatrix} = \begin{bmatrix} \mathbf{I} \\ \mathbf{F} \end{bmatrix} \mathbf{x}_0 + \begin{bmatrix} 0 \\ \mathbf{I} \end{bmatrix} \mathbf{w}_0 \quad (3)$$

$$\begin{bmatrix} \mathbf{z}_0 \\ \mathbf{z}_1 \end{bmatrix} = \begin{bmatrix} \mathbf{H}\mathbf{x}_0 + \mathbf{v}_0 \\ \mathbf{H}\mathbf{x}_1 + \mathbf{v}_1 \end{bmatrix} = \begin{bmatrix} \mathbf{H} \\ \mathbf{H}\mathbf{F} \end{bmatrix} \mathbf{x}_0 + \begin{bmatrix} 0 \\ \mathbf{H} \end{bmatrix} \mathbf{w}_0 + \begin{bmatrix} \mathbf{v}_0 \\ \mathbf{v}_1 \end{bmatrix} \quad (4)$$

Obecná rovnice pro měření je definována následovně:

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x} + \mathbf{v} \quad (5)$$

V dalším kroku definujeme metodu maximální věrohodnosti (z angl. *maximum likelihood*), zkratka ML. Odhad budeme volit jako takovou hodnotu parametru \mathbf{x} , při které má dané měření největší pravděpodobnost (resp. hodnotu hustoty). Dostaneme tedy následující vztah:

$$\hat{\mathbf{x}}_{\text{ML}}(\mathbf{z}) = \underset{\mathbf{x}}{\operatorname{argmax}} p_{\mathbf{z};\mathbf{x}}(\mathbf{z}; \mathbf{x}), \quad (6)$$

kde \mathbf{z} reprezentuje měření, která chceme použít, a $p_{\mathbf{z};\mathbf{x}}(\mathbf{z}; \mathbf{x})$ (věrohodnostní funkce) je hustota pravděpodobnosti měření závislá na hledaném parametru \mathbf{x} . Jelikož v praxi bývá $p_{\mathbf{z};\mathbf{x}}$ často v exponenciálním tvaru, je možné využít přirozený logaritmus, což je monotónní rostoucí funkce. Metodu maximální věrohodnosti lze tedy rovněž definovat následujícím způsobem:

$$\hat{\mathbf{x}}_{\text{ML}}(\mathbf{z}) = \underset{\mathbf{x}}{\operatorname{argmax}} \ln p_{\mathbf{z};\mathbf{x}}(\mathbf{z}; \mathbf{x}), \quad (7)$$

Pro získání věrohodnostní funkce $p_{\mathbf{z};\mathbf{x}}(\mathbf{z}; \mathbf{x})$, která je potřeba pro využití metody ML, využijeme transformaci náhodných veličin. V některých případech je možné charakterizovat vztah mezi měřením \mathbf{z} a parametrem \mathbf{x} funkční závislostí (náhodná veličina \mathbf{z} daná transformací parametru \mathbf{x}). Tím pádem ale nedošlo ke vzniku "náhody", z důvodu, že \mathbf{x} je konstantní nenáhodný vektor. Do procesu měření přispívá tedy ještě nějaká konkrétní veličina \mathbf{v} . Z toho vyplývá, že se budeme zabývat transformací náhodné veličiny \mathbf{v} na veličinu \mathbf{z} v následujícím tvaru:

$$\mathbf{z} = f(\mathbf{v}; \mathbf{x}), \quad (8)$$

kde f je funkcí zobrazení parametru \mathbf{x} . Pokud platí $\mathbf{v}, \mathbf{z} \in \mathbb{R}^n$ a zobrazení $f \in \mathbb{R}^n \rightarrow \mathbb{R}^n$ prosté, pak lze pro transformaci využít následující rovnici:

$$p_{\mathbf{z};\mathbf{x}}(\mathbf{z};\mathbf{x}) = p_{\mathbf{v}}(f^{-1}(\mathbf{z};\mathbf{x})) \cdot |\det(\mathbf{J}_{f^{-1}}(\mathbf{z};\mathbf{x}))| = \frac{p_{\mathbf{v}}(f^{-1}(\mathbf{z};\mathbf{x}))}{|\det(\mathbf{J}_{\mathbf{f}}(\mathbf{v};\mathbf{x}))|}, \quad (9)$$

kde f^{-1} je inverzní zobrazení k f a $\mathbf{J}_{\mathbf{f}} = \frac{\partial f}{\partial \mathbf{z}}$ je Jakobiova matice zobrazení f .

Jestliže existuje lineární vztah ve tvaru:

$$\mathbf{z} = \mathbf{H}\mathbf{x} + \mathbf{v}, \quad (10)$$

pak lze aplikovat vztah (9).

$$f(\mathbf{v};\mathbf{x}) = (\mathbf{I}\mathbf{v} + \mathbf{H}\mathbf{x}) \implies f^{-1}(\mathbf{z};\mathbf{x}) = (\mathbf{I}\mathbf{z} - \mathbf{H}\mathbf{x}) \quad (11)$$

$$\mathbf{J}_{\mathbf{f}}(\mathbf{v};\mathbf{x}) = \mathbf{I} \implies \mathbf{J}_{f^{-1}}(\mathbf{v};\mathbf{x}) = \mathbf{I} \quad (12)$$

Po dosazení do rovnice (9) dostaneme hustotu pravděpodobnosti pro \mathbf{z} :

$$p_{\mathbf{z};\mathbf{x}}(\mathbf{z};\mathbf{x}) = p_{\mathbf{v}}(\mathbf{z} - \mathbf{H}\mathbf{x}) \cdot 1 \quad (13)$$

Pokud je navíc veličina \mathbf{v} gaussovská, což v našem případě je, dostaneme $p_{\mathbf{z};\mathbf{x}}(\mathbf{z};\mathbf{x}) = \mathcal{N}(\mathbf{z} - \mathbf{H}\mathbf{x}; \mathbf{0}, \mathbf{R}) = \mathcal{N}(\mathbf{z}; \mathbf{H}\mathbf{x}, \mathbf{R})$. Odhad ve smyslu ML je pak definován jako:

$$\begin{aligned} \hat{\mathbf{x}}_{\text{ML}}(\mathbf{z}) &= \operatorname{argmax}_{\mathbf{x}} p_{\mathbf{z};\mathbf{x}}(\mathbf{z};\mathbf{x}) \\ &= \operatorname{argmax}_{\mathbf{x}} \ln p_{\mathbf{z};\mathbf{x}}(\mathbf{z};\mathbf{x}) \\ &= \operatorname{argmax}_{\mathbf{x}} \ln \left(\frac{1}{\sqrt{\det(2\pi \cdot \mathbf{R})}} \exp \left(-\frac{1}{2}(\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1}(\mathbf{z} - \mathbf{H}\mathbf{x}) \right) \right) \\ &= \operatorname{argmax}_{\mathbf{x}} \ln \left(\frac{1}{\sqrt{\det(2\pi \cdot \mathbf{R})}} \right) + \left(-\frac{1}{2}(\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1}(\mathbf{z} - \mathbf{H}\mathbf{x}) \right) \\ &= \operatorname{argmax}_{\mathbf{x}} -(\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1}(\mathbf{z} - \mathbf{H}\mathbf{x}) \\ &= \operatorname{argmin}_{\mathbf{x}} (\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1}(\mathbf{z} - \mathbf{H}\mathbf{x}) \end{aligned} \quad (14)$$

Po parciální derivaci věrohodnostní funkce podle \mathbf{x} a změně značení matice \mathbf{R} na $\mathbf{\Sigma}$ dostaneme kritérium maximální věrohodnosti v následujícím tvaru:

$$\hat{\mathbf{x}}_{\text{ML}}(\mathbf{z}) = (\mathbf{H}^T \mathbf{\Sigma}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{\Sigma}^{-1} \mathbf{z} \quad (15)$$

Nyní zavedeme chybu e , která je definována následovně:

$$e = \begin{bmatrix} \mathbf{v}_0 \\ \mathbf{H}\mathbf{w}_0 + \mathbf{v}_1 \end{bmatrix} \quad (16)$$

V dalším kroku je již možné vypočítat kovarianční matici $\mathbf{\Sigma} = E(ee^T)$ chyby e .

$$ee^T = \begin{bmatrix} \mathbf{v}_0 \\ \mathbf{H}\mathbf{w}_0 + \mathbf{v}_1 \end{bmatrix} \begin{bmatrix} \mathbf{v}_0 & \mathbf{H}\mathbf{w}_0 + \mathbf{v}_1 \end{bmatrix} = \begin{bmatrix} v_0^2 & v_0(v_1 + \mathbf{H}\mathbf{w}_0) \\ v_0(v_1 + \mathbf{H}\mathbf{w}_0) & (v_1 + \mathbf{H}\mathbf{w}_0)^2 \end{bmatrix} \quad (17)$$

$$\mathbf{\Sigma} = \begin{bmatrix} \mathbf{R} & 0 \\ 0 & \mathbf{H}^2 \mathbf{Q} + \mathbf{R} \end{bmatrix} = \begin{bmatrix} \mathbf{R} & 0 \\ 0 & \frac{T^3}{30} + \mathbf{R} \end{bmatrix} \quad (18)$$

$$\mathbf{H} = \begin{bmatrix} \mathbf{H} \\ \mathbf{H}\mathbf{F} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 1 & T \end{bmatrix} \quad (19)$$

Nyní je možné dosadit do rovnice (15). Po dosazení dostaneme obecný tvar:

$$\hat{\mathbf{x}}_{\text{ML}}(\mathbf{z}) = \begin{bmatrix} 1 & 0 \\ -\frac{1}{T} & \frac{30\left(\frac{T^3+60}{30T^2}-\frac{1}{T}\right)}{T^3+30} \end{bmatrix} \begin{bmatrix} z_0 \\ z_1 \end{bmatrix} \quad (20)$$

Po dosazení do rovnice (20) za $T = 1$ dostaneme:

$$\hat{\mathbf{x}}_{\text{ML}}(\mathbf{z}) = \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} z_0 \\ z_1 \end{bmatrix} \quad (21)$$

Dále byla vypočtena kovarianční matice (chyby) ML odhadu. V případě, že je ignorována apriorní informace je kovarianční matice ML odhadu totožná s kovarianční maticí chyby ML odhadu. Stačilo tedy vypočítat pouze jednu matici pomocí následujícího vzorce:

$$\mathbf{P}_{\hat{\mathbf{x}}_{\text{ML}}} = \mathbf{P}_{\hat{\mathbf{x}}_{\text{ML}}} = (\mathbf{H}^T \mathbf{\Sigma}^{-1} \mathbf{H})^{-1} \quad (22)$$

Po dosazení do rovnice (22) jsme dostali následující výsledek:

$$\mathbf{P}_{\hat{\mathbf{x}}_{\text{ML}}} = \mathbf{P}_{\hat{\mathbf{x}}_{\text{ML}}} = \begin{bmatrix} 1 & -1 \\ -1 & \frac{61}{30} \end{bmatrix} \quad (23)$$

V prvním případě jsme ignorovali zadanou apriorní informaci. Nyní ji vezmeme v potaz a určíme nejlepší lineární odhad ve smyslu střední kvadratické chyby při použití měření A) z_0 , B) z_1 a C) \mathbf{z} . Optimální lineární odhad ve smyslu střední kvadratické chyby (LMSE odhad) je možné vypočítat pomocí následující rovnice, která byla definována na přednášce:

$$\hat{\mathbf{x}}_{\text{LMSE}}(\mathbf{z}) = \mathbf{E}[\mathbf{x}] + \mathbf{P}_{\mathbf{x}\mathbf{z}} \mathbf{P}_{\mathbf{z}}^{-1} (\mathbf{z} - \mathbf{E}[\mathbf{z}]), \quad (24)$$

kde rozdíl $\hat{\mathbf{z}} = \mathbf{z} - \mathbf{E}[\mathbf{z}]$ označujeme jako rezidua, střední hodnota $\mathbf{E}[\mathbf{x}]$ je apriorní odhad \mathbf{x} , $\mathbf{P}_{\mathbf{x}\mathbf{z}} \mathbf{P}_{\mathbf{z}}^{-1} (\mathbf{z} - \mathbf{E}[\mathbf{z}])$ je korekce založená na reziduu a $\mathbf{E}[\mathbf{z}]$ je odhad měření \mathbf{z} .

Jednotlivé členy lze získat následovně pomocí následujících vztahů (výsledné vztahy byly odvozeny na přednášce):

$$\mathbf{P}_{\mathbf{x}\mathbf{z}} = \mathbf{P}_{\mathbf{x}} \mathbf{H}^T \quad (25)$$

$$\mathbf{P}_{\mathbf{z}} = \mathbf{H} \mathbf{P}_{\mathbf{x}} \mathbf{H}^T + \mathbf{\Sigma} \quad (26)$$

$$\mathbf{E}[\mathbf{z}] = \mathbf{H} \hat{\mathbf{x}} \quad (27)$$

Nyní můžeme určit lineární odhady ve smyslu střední kvadratické chyby pro jednotlivá měření.

(A) Měření z_0

Pro vypočtení optimálního lineárního odhadu využijeme rovnic (25), (26) a (27). V tomto případě

$$\mathbf{P}_{\mathbf{x}} = \begin{bmatrix} 1 & 1 \\ 1 & 4 \end{bmatrix}, \mathbf{H} = \begin{bmatrix} 1 & 0 \end{bmatrix} \text{ a } \mathbf{\Sigma} = \mathbf{R} = 1.$$

$$\hat{\mathbf{x}}_{\text{LMSE}}(z_0) = \begin{bmatrix} \frac{\bar{x}_0^{\text{poloha}}}{2} + \frac{z_0}{2} \\ \bar{x}_0^{\text{rychlost}} - \frac{\bar{x}_0^{\text{poloha}}}{2} + \frac{z_0}{2} \end{bmatrix} \quad (28)$$

(B) **Měření z_1**

Opět začneme postupně dosazovat do rovnic (25), (26) a (27). V tomto případě $\mathbf{P}_x = \begin{bmatrix} 1 & 1 \\ 1 & 4 \end{bmatrix}$,

$$\mathbf{H} = \begin{bmatrix} 1 & T \end{bmatrix} \text{ a } \mathbf{\Sigma} = \mathbf{R} + \frac{T^3}{30} = 1 + \frac{T^3}{30} = \frac{31}{30}.$$

$$\hat{\mathbf{x}}_{\text{LMSE}}(z_1) = \frac{1}{241} \begin{bmatrix} 181\bar{x}_0^{\text{poloha}} - 60\bar{x}_0^{\text{rychlost}} + 60z_1 \\ 91\bar{x}_0^{\text{rychlost}} - 150\bar{x}_0^{\text{poloha}} + 150z_1 \end{bmatrix} \quad (29)$$

(C) **Měření z**

Opět začneme postupně dosazovat do rovnic (25), (26) a (27). V tomto případě $\mathbf{P}_x = \begin{bmatrix} 1 & 1 \\ 1 & 4 \end{bmatrix}$,

$$\mathbf{H} = \begin{bmatrix} 1 & 0 \\ 1 & T \end{bmatrix} \text{ a } \mathbf{\Sigma} = \begin{bmatrix} \mathbf{R} & 0 \\ 0 & \frac{T^3}{30} + \mathbf{R} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & \frac{31}{30} \end{bmatrix}$$

$$\hat{\mathbf{x}}_{\text{LMSE}}(z) = \frac{1}{362} \begin{bmatrix} 181\bar{x}_0^{\text{poloha}} - 60\bar{x}_0^{\text{rychlost}} + 121z_0 + 60z_1 \\ 122\bar{x}_0^{\text{rychlost}} - 181\bar{x}_0^{\text{poloha}} - 59z_0 + 240z_1 \end{bmatrix} \quad (30)$$

V další části byly vyjádřeny kovarianční matice chyb odhadů, jinak také míry důvěry, pro všechny případy. K výpočtu jednotlivých kovariančních matic chyb odhadů byl použit následující konečný vzorec, který byl odvozen na přednášce:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \mathbf{P}_{\mathbf{x}} - \mathbf{P}_{\mathbf{x}\mathbf{z}}\mathbf{P}_{\mathbf{z}}^{-1}\mathbf{P}_{\mathbf{z}\mathbf{x}}, \quad (31)$$

kde $\mathbf{P}_{\mathbf{x}}$ představuje apriorní kovarianci chyby a člen $\mathbf{P}_{\mathbf{z}}^{-1}\mathbf{P}_{\mathbf{z}\mathbf{x}}\mathbf{P}_{\mathbf{x}}\mathbf{P}_{\mathbf{z}}^{-1}\mathbf{P}_{\mathbf{z}\mathbf{x}}$ reprezentuje redukci neurčitosti díky měření.

(A) **Měření z_0**

Pro vypočtení kovarianční matice chyby odhadu byl využit vztah (31). Dostali jsme matici v následujícím tvaru:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 7 \end{bmatrix} \quad (32)$$

(B) **Měření z_1**

Pro vypočtení kovarianční matice chyby odhadu byl opět využit vztah (31). Dostali jsme matici v následujícím tvaru:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \frac{1}{241} \begin{bmatrix} 121 & -59 \\ -59 & 214 \end{bmatrix} \quad (33)$$

(C) **Měření z**

Pro vypočtení kovarianční matice chyby odhadu byl opět využit vztah (31). Dostali jsme matici v následujícím tvaru:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \frac{1}{362} \begin{bmatrix} 121 & -59 \\ -59 & 307 \end{bmatrix} \quad (34)$$

Apriorní informace nám říká, že se veličina \mathbf{x}_0 řídí podle normálního rozdělení o dané střední hodnotě a dané vzájemné kovarianci mezi polohou a zrychlením. Z kovarianční matice je dále možné vypočítávat závislost mezi polohou a zrychlením, a to jelikož $\text{cov}[\text{poloha}, \text{rychlost}] \neq 0$. Apriorní informace byla nejprve využita v rovnici pro výpočet odhadu ve smyslu LMSE (24), kde byla využita pro získání apriorního odhadu \mathbf{x} ve tvaru střední hodnoty $E[\mathbf{x}]$. Dále se apriorní informace projevila ve formě apriorní kovariance $\mathbf{P}_{\mathbf{x}}$ v rovnicích (25), (26) a (31)

Následně byly vypočteny jednotlivé kovarianční matice odhadu LMSE opět pro všechna měření. K výpočtu byl použit následující vzorec:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \mathbf{P}_{\mathbf{x}\mathbf{z}}\mathbf{P}_{\mathbf{z}}^{-1}\mathbf{P}_{\mathbf{z}\mathbf{x}} \quad (35)$$

(A) **Měření z_0**

Pro vypočtení kovarianční matice odhadu byl využit vztah (35). Dostali jsme matici v následujícím tvaru:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \quad (36)$$

(B) **Měření z_1**

Pro vypočtení kovarianční matice odhadu byl opět využit vztah (35). Dostali jsme matici v následujícím tvaru:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \frac{1}{241} \begin{bmatrix} 120 & 300 \\ 300 & 750 \end{bmatrix} \quad (37)$$

(C) **Měření \mathbf{z}**

Pro vypočtení kovarianční matice odhadu byl opět využit vztah (35). Dostali jsme matici v následujícím tvaru:

$$\mathbf{P}_{\hat{\mathbf{x}}} = \frac{1}{362} \begin{bmatrix} 241 & 421 \\ 421 & 1141 \end{bmatrix} \quad (38)$$

2.1.2 Úkol (ii)

Cílem druhého úkolu je pozorovat, co se může stát, pokud k návrhu estimátoru budou použity špatné znalosti parametrů systému. K tomuto účelu byl uvažován pouze LMSE případ C), tj. měření \mathbf{z} . Postupně byly sestaveny odhady s následujícími hodnotami parametrů: a) $R = \frac{1}{4}$, b) $R = 4$ a c) $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$.

a) $R = \frac{1}{4}$

$$\hat{\mathbf{x}}_{\text{LMSE}}(\mathbf{z}) = \frac{1}{1225} \begin{bmatrix} 317\bar{x}_0^{\text{poloha}} - 120\bar{x}_0^{\text{rychlost}} + 788z_0 + 120z_1 \\ 205\bar{x}_0^{\text{rychlost}} - 368\bar{x}_0^{\text{poloha}} - 652z_0 + 1020z_1 \end{bmatrix} \quad (39)$$

b) $R = 4$

$$\hat{\mathbf{x}}_{\text{LMSE}}(\mathbf{z}) = \frac{1}{1535} \begin{bmatrix} 1084\bar{x}_0^{\text{poloha}} - 240\bar{x}_0^{\text{rychlost}} + 211z_0 + 240z_1 \\ 845\bar{x}_0^{\text{rychlost}} - 721\bar{x}_0^{\text{poloha}} + 31z_0 + 690z_1 \end{bmatrix} \quad (40)$$

c) $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$

$$\hat{\mathbf{x}}_{\text{LMSE}}(\mathbf{z}) = \frac{1}{362} \begin{bmatrix} 181\bar{x}_0^{\text{poloha}} - 60\bar{x}_0^{\text{rychlost}} + 121z_0 + 60z_1 - 905 \\ 122\bar{x}_0^{\text{rychlost}} - 181\bar{x}_0^{\text{poloha}} - 59z_0 + 240z_1 + 905 \end{bmatrix} \quad (41)$$

Dále byly dopočítány kovarianční matice chyb založené na nesprávných hodnotách parametrů. K výpočtu kovariančních matic chyb byl použit vztah (31).

a) $R = \frac{1}{4}$

$$\mathbf{P}_{\tilde{\mathbf{x}}} = \frac{1}{1225} \begin{bmatrix} 197 & -163 \\ -163 & 452 \end{bmatrix} \quad (42)$$

b) $R = 4$

$$\mathbf{P}_{\tilde{\mathbf{x}}} = \begin{bmatrix} \frac{844}{1535} & \frac{124}{1535} \\ \frac{124}{1535} & \frac{1171}{676} \end{bmatrix} \quad (43)$$

c) $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$

$$\mathbf{P}_{\tilde{\mathbf{x}}} = \frac{1}{362} \begin{bmatrix} 121 & -59 \\ -59 & 307 \end{bmatrix} \quad (44)$$

Lze si povšimnout, že kovarianční matice chyby, poskytnutá algoritmem odhadu, pro případ c) je ekvivalentní se skutečnou kovarianční maticí chyby odhadu (34) pro měření \mathbf{z} , která již byla vypočtena výše. Naopak v obou zbylých případech a) a b) získané kovarianční matice chyb odhadu nejsou ekvivalentní se skutečnou kovarianční maticí chyby odhadu, jelikož volba nesprávného parametru R ovlivní výpočet $\mathbf{P}_{\tilde{\mathbf{x}}}$.

Z přednášky víme, že nestrannost odhadu lze určit použitím následujícího vztahu:

$$\begin{aligned} \mathbb{E}[\hat{\mathbf{x}}_{\text{LMSE}}] &= \mathbb{E}[\mathbb{E}[\mathbf{x}] + \mathbf{P}_{\mathbf{xz}}\mathbf{P}_{\mathbf{z}}^{-1}(\mathbf{z} - \mathbb{E}[\mathbf{z}])] = \\ &= \mathbb{E}[\mathbb{E}[\mathbf{x}]] + \mathbb{E}[\mathbf{P}_{\mathbf{xz}}\mathbf{P}_{\mathbf{z}}^{-1}(\mathbf{z} - \mathbb{E}[\mathbf{z}])] = \\ &= \mathbb{E}[\mathbf{x}] + \mathbf{P}_{\mathbf{xz}}\mathbf{P}_{\mathbf{z}}^{-1}(\mathbb{E}[\mathbf{z}] - \mathbb{E}[\mathbf{z}]) \end{aligned} \quad (45)$$

Odhady $\hat{\mathbf{x}}_{\text{LMSE}}(\mathbf{z})$ získané pro případy a) a b) budou nestranné, protože volba parametru R ovlivní pouze matici $\mathbf{P}_{\mathbf{z}}^{-1}$. Tím pádem v těchto případech platí: $\mathbb{E}[\hat{\mathbf{x}}_{\text{LMSE}}(\mathbf{z})] = \mathbb{E}[\mathbf{x}]$, a tudíž:

$$\mathbb{E}[\tilde{\mathbf{x}}] = \mathbb{E}[\mathbf{x} - \hat{\mathbf{x}}_{\text{LMSE}}] = \mathbb{E}[\mathbf{x}] - \mathbb{E}[\mathbf{x}] = 0. \quad (46)$$

Naopak odhad pro případ c) bude stranný, jelikož posun počáteční střední hodnoty $\bar{x}_0^{\text{poloha}}$ o -5 ovlivní nejen matici $\mathbf{P}_{\mathbf{x}z}$, ale i střední hodnotu $E[\mathbf{z}]$ (rovnice (27)), kde vektor $\hat{\mathbf{x}} = \begin{bmatrix} \bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5 \\ \bar{x}_0^{\text{rychlost}} \end{bmatrix}$.

Pro případ c) tedy platí s využitím rovnic (45) a (46):

$$\begin{aligned}
E[\tilde{\mathbf{x}}_0] &= E[\mathbf{x}_0 - \hat{\mathbf{x}}] = \\
&= E \left[\mathbf{x}_0 - E[\hat{\mathbf{x}}] - \mathbf{P}_{\mathbf{x}_0\mathbf{z}} \mathbf{P}_{\mathbf{z}}^{-1} \underbrace{(\mathbf{z} - E[\mathbf{z}])}_{\mathbf{H}\mathbf{x}} \right] = \\
&= E[\mathbf{x}_0 - E[\hat{\mathbf{x}}]] - \mathbf{P}_{\mathbf{x}_0\mathbf{z}} \mathbf{P}_{\mathbf{z}}^{-1} \mathbf{H} E[\mathbf{x}] + \mathbf{P}_{\mathbf{x}_0\mathbf{z}} \mathbf{P}_{\mathbf{z}}^{-1} \mathbf{H} E[\hat{\mathbf{x}}] = \\
&= E[\mathbf{x}_0] - E[\hat{\mathbf{x}}] - \mathbf{P}_{\mathbf{x}_0\mathbf{z}} \mathbf{P}_{\mathbf{z}}^{-1} \mathbf{H} E[\mathbf{x}] + \mathbf{P}_{\mathbf{x}_0\mathbf{z}} \mathbf{P}_{\mathbf{z}}^{-1} \mathbf{H} E[\hat{\mathbf{x}}] = \\
&= \begin{bmatrix} 0 \\ 0 \end{bmatrix} - \begin{bmatrix} -5 \\ 0 \end{bmatrix} - \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} -2.5 \\ -2.5 \end{bmatrix} = \\
&= \begin{bmatrix} 2.5 \\ -2.5 \end{bmatrix}
\end{aligned} \tag{47}$$

2.1.3 Úkol (iii)

Cílem tohoto úkolu bylo vykreslení 3- σ elips, které odpovídají chybám odhadu. Pro odhad s kovarianční maticí chyby odhadu \mathbf{P} se jedná o křivku definovanou následující rovnicí:

$$\mathbf{x} \in \mathbb{R}^2 : (\mathbf{x} - \mathbf{b})^T \mathbf{P}^{-1} (\mathbf{x} - \mathbf{b}) = 9, \quad (48)$$

kde $\mathbf{b} = E(\mathbf{x}_0 - \hat{\mathbf{x}}_0)$. Pro získání jednotlivých 3- σ elips bylo třeba nejprve nalézt křivky, které splňují následující předpis:

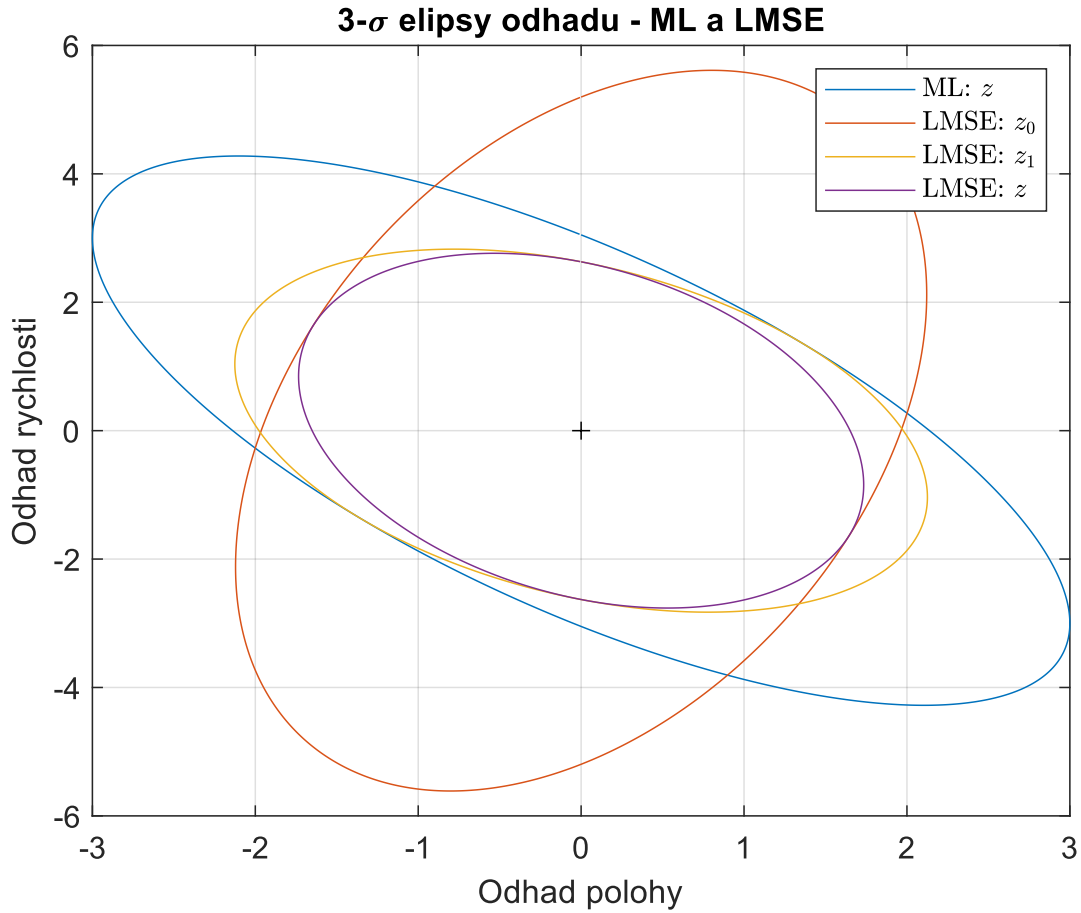
$$\mathbf{u} \in \mathbb{R}^2 : \mathbf{u}^T \mathbf{u} = 1, \quad (49)$$

což je rovnice, pomocí které může být definována jednotková kružnice.

Na rovnici (49) je třeba následně použít transformaci, která je zadaná pomocí následující rovnice:

$$\mathbf{x} = \mathbf{x}_0 + 3\mathbf{S}\mathbf{u}, \quad (50)$$

kde \mathbf{S} je maticová odmocnina matice \mathbf{P} splňující kritérium $\mathbf{S}\mathbf{S}^T = \mathbf{P}$, což je např. Choleského faktor. V našem případě byla matice \mathbf{S} kovarianční maticí chyby odhadu.

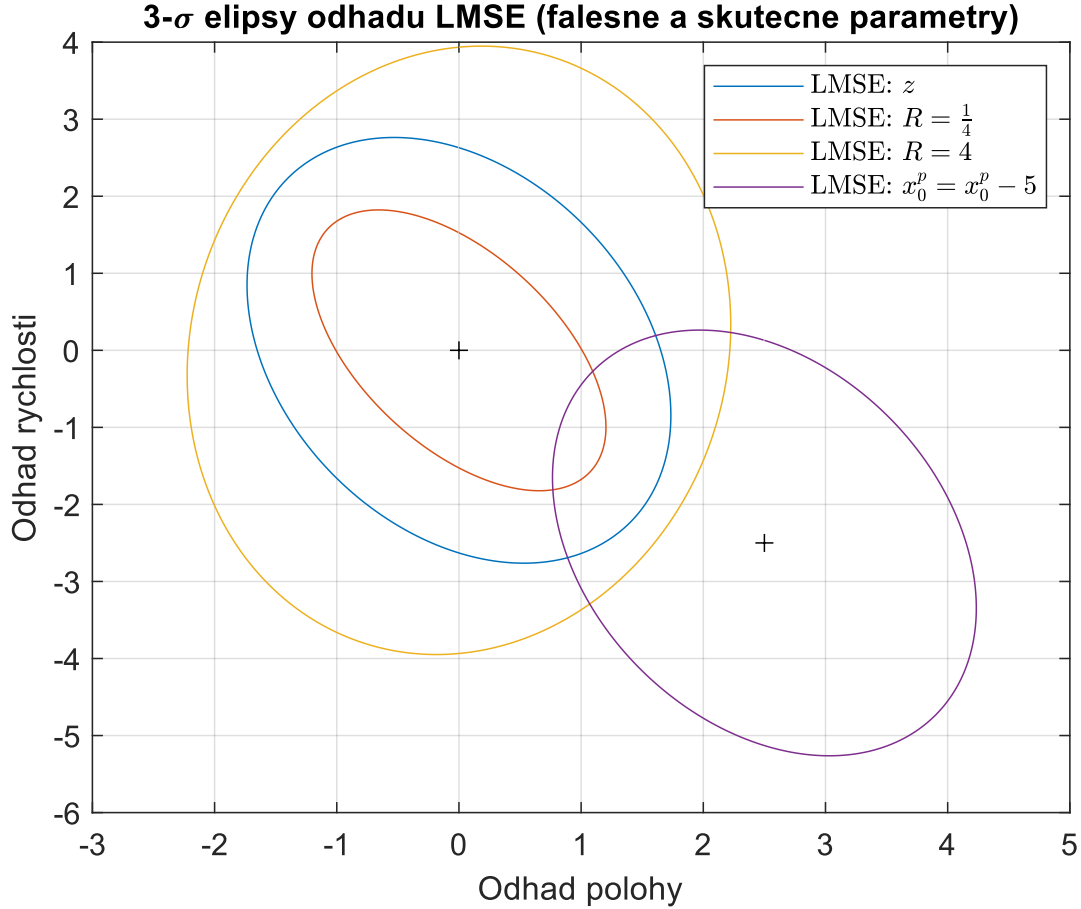


Obrázek 1: Vykreslení 3- σ elips, které odpovídají chybám odhadů, kde $E[\mathbf{x}_0] = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$.

Z obrázku (1) je patrné, že pokud využíváme k odhadu ve smyslu LMSE všechna dostupná měření, pak bude daná 3- σ elipsa nejmenší. Tento poznatek nám indikuje, že daný odhad bude nejpresnější a bude

mít nejmenší varianci. Tato elipsa se navíc nachází uvnitř obou elips, které obsahují pouze jedno ze dvou měření. Dále je možné z obrázku (1) zjistit, že největší $3\text{-}\sigma$ elipsou je elipsa reprezentující chybu odhadu ve smyslu ML, což je způsobeno tím, že při odhadování pomocí ML nepoužíváme apriorní informaci.

Dále byly vykresleny $3\text{-}\sigma$ elipsy pro kovarianční matice chyb odhadu s nesprávnými parametry systému (matice získané v teoretickém úkolu (ii)) poskytované algoritmem odhadu, společně s $3\text{-}\sigma$ elipsou reprezentující skutečnou kovarianční matici chyby odhadu (34).



Obrázek 2: Vykreslení $3\text{-}\sigma$ elips, které odpovídají kovariančním maticím chyb s falešnými parametry, společně s $3\text{-}\sigma$ elipsou odpovídající skutečné kovarianční matici chyby odhadu LMSE: \mathbf{z} .

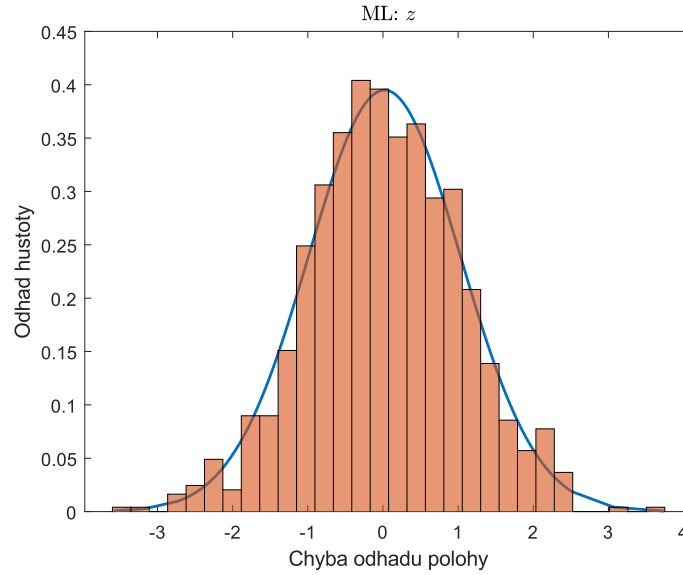
Z obrázku (2) vyplývá, že elipsa reprezentující odhad LMSE (měření \mathbf{z}) s parametrem $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$ bude totožná jako elipsa reprezentující odhad LMSE (měření \mathbf{z}), pouze bude posunut její střed do bodu $[2.5, -2.5]^T$ (viz vyšetřování strannosti odhadů). Dále je možné vypořadovat, že při volbě parametru $R = 4$ dojde ke zvětšení elipsy (oproti základní elipse LMSE: \mathbf{z}), jelikož dáváme měření menší váhu. Naopak volbou parametru $R = \frac{1}{4}$ říkáme, že věříme získanému měření, tj. dáváme měření větší váhu, a tím pádem je daná elipsa menší než základní elipsa LMSE: \mathbf{z} .

2.2 Simulační úkoly


Nejprve bylo třeba pomocí funkce *randn* vygenerovat 1000 simulací vektoru $[\mathbf{x}_0^T, \mathbf{z}^T]^T$. Následně byly pro každý nasimulovaný vektor dopočítány realizace odhadů $\hat{\mathbf{x}}_0$ a rovněž chyby odhadů $\tilde{\mathbf{x}}_0 = \mathbf{x}_0 - \hat{\mathbf{x}}_0$.

2.2.1 Úkol (i)

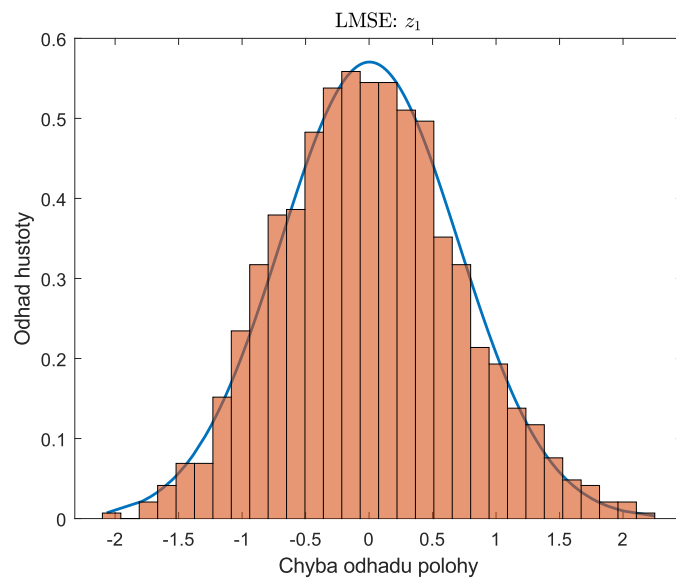
V této části byly nejprve odhadnuty hustoty jednotlivých odhadů *polohy* pomocí normalizovaných histogramů. V dalším kroku byly jednotlivé histogramy proloženy, pomocí techniky přiřazení momentů, gaussovskými hustotami.




Obrázek 3: Normalizovaný histogram proložený hustotou pro metodu ML (měření z).



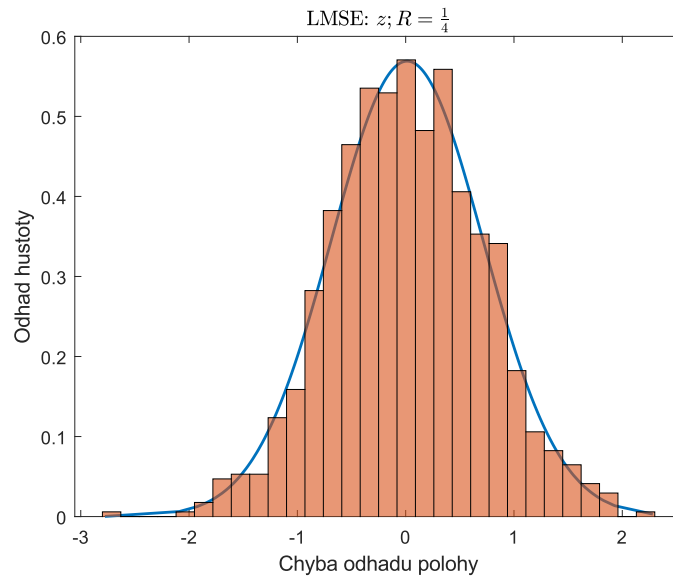
Obrázek 4: Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z_0).




Obrázek 5: Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z_1).



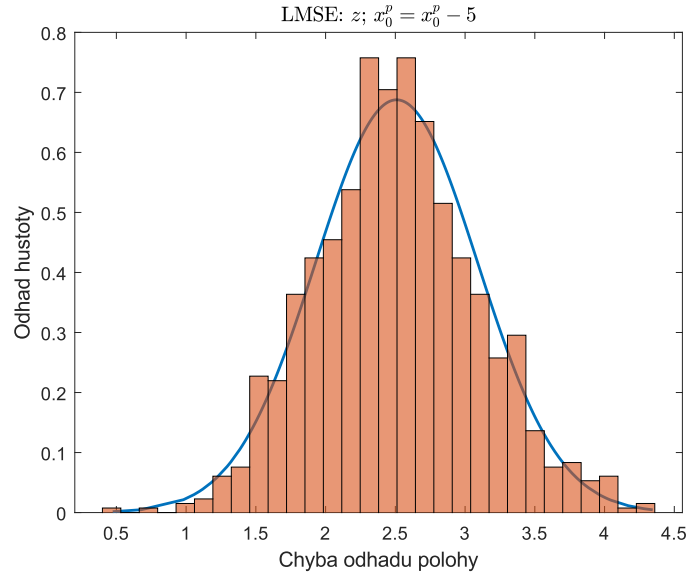
Obrázek 6: Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z).



Obrázek 7: Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z) s falešným parametrem $R = \frac{1}{4}$.

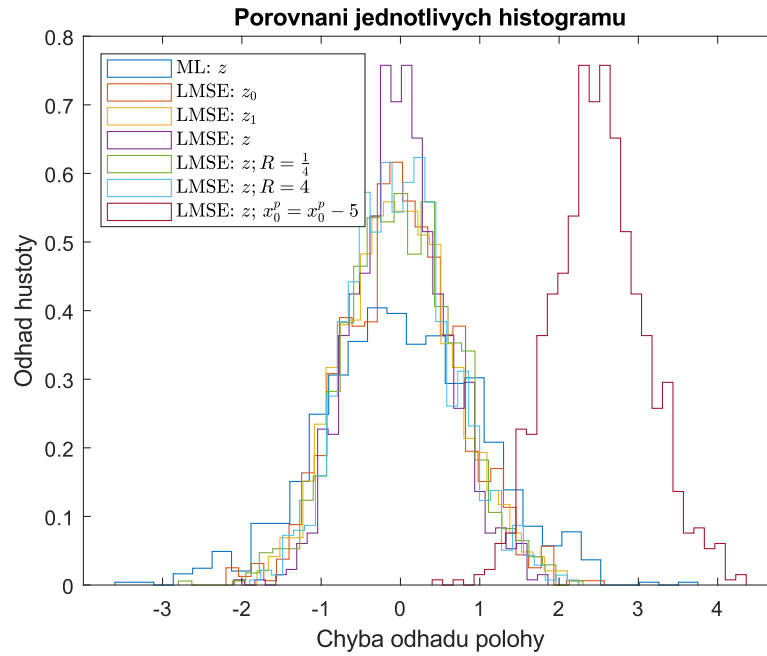


Obrázek 8: Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z) s falešným parametrem $R = 4$.

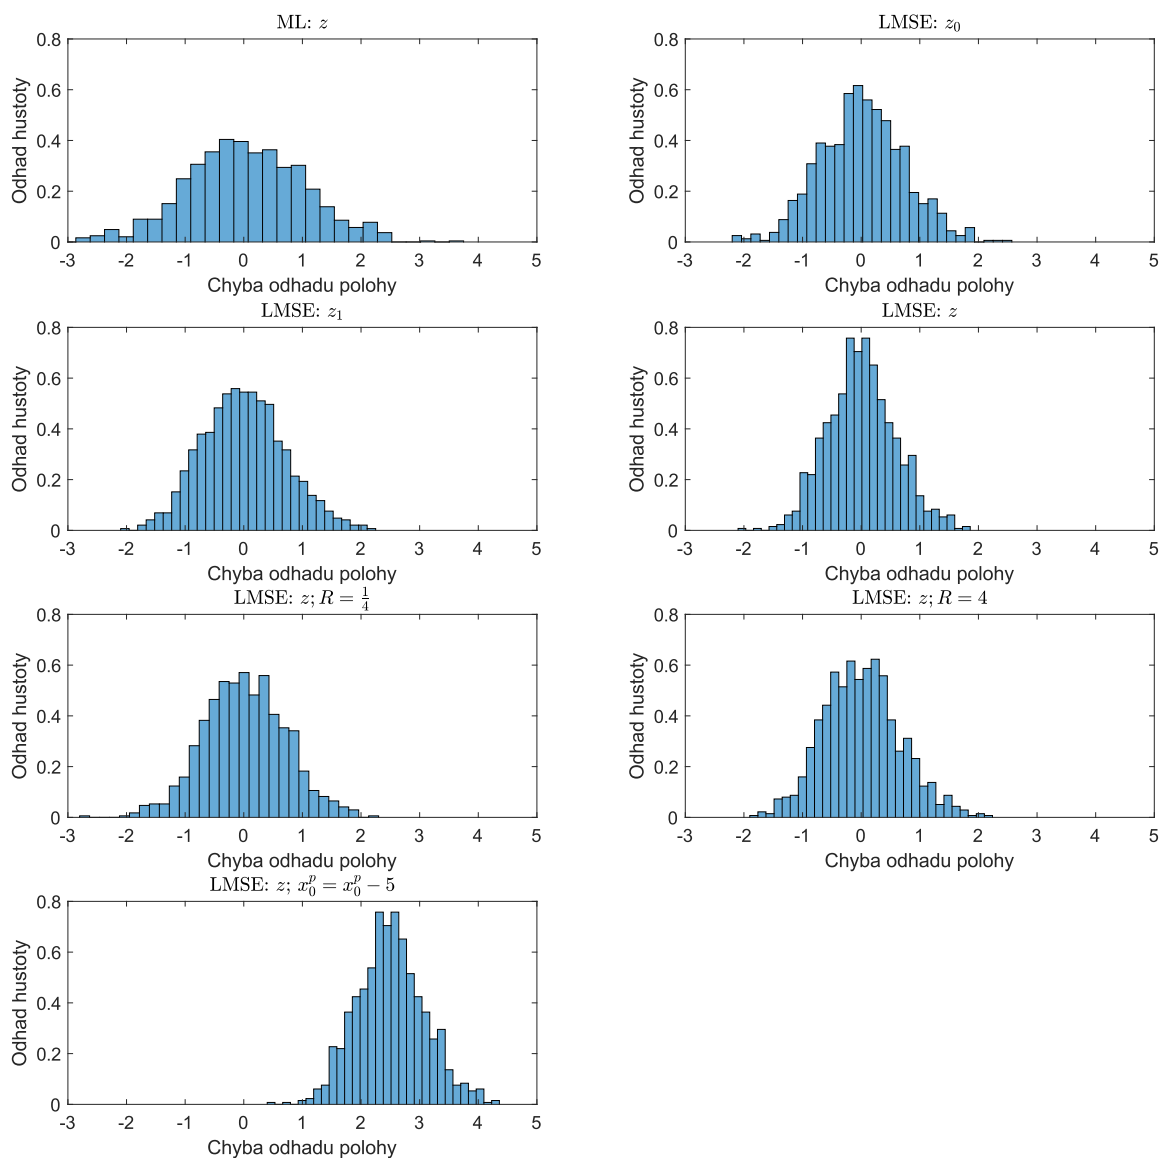


Obrázek 9: Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z) s počáteční střední hodnotou $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$

V dalším kroku byly mezi sebou porovnány jednotlivé histogramy, nejprve jsme si vykreslili pouze obrysy jednotlivých histogramů a v dalším kroku byly histogramy vykresleny pomocí *subplotu*.

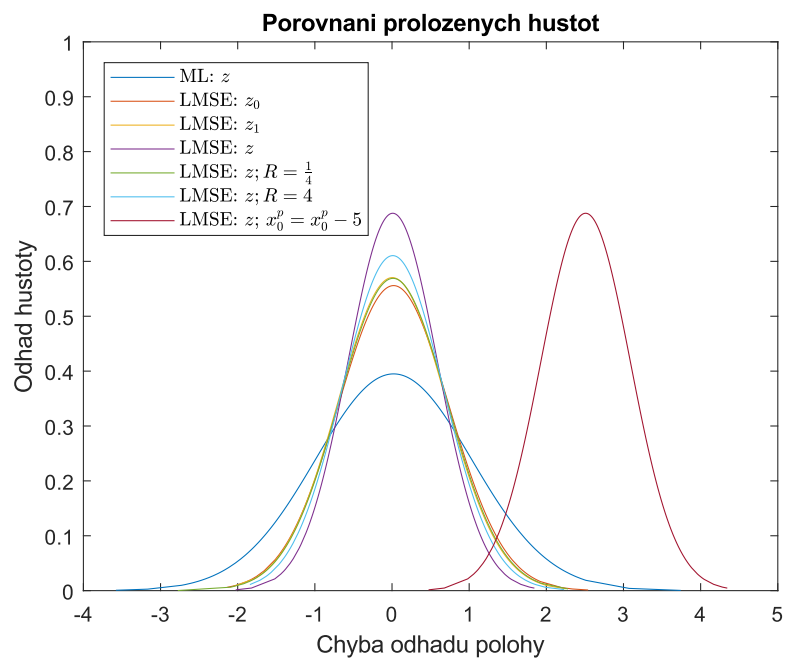


Obrázek 10: Porovnání obrysů jednotlivých normalizovaných histogramů.

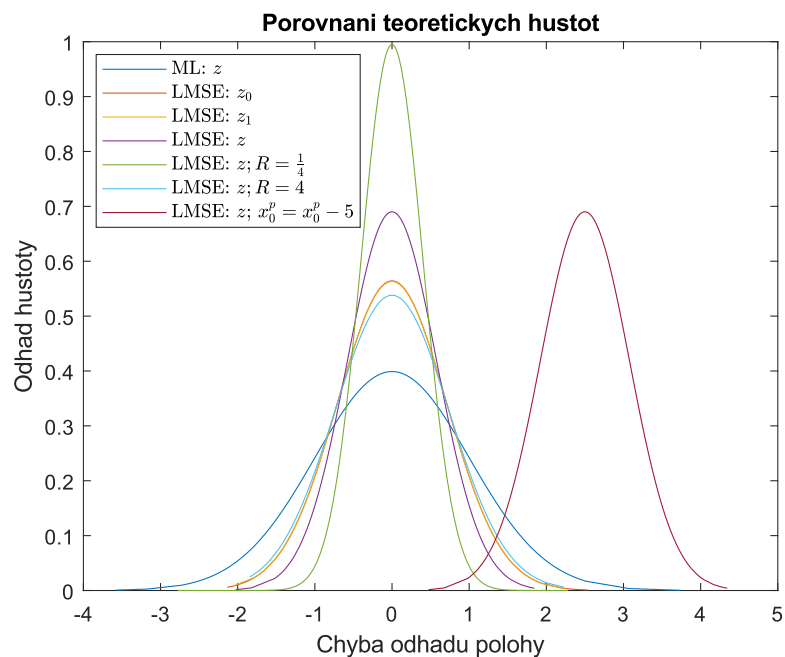


Obrázek 11: Porovnání normalizovaných histogramů pomocí *subplotu*.

Dále byly mezi sebou vzájemně porovnány jednotlivé proložené hustoty a rovněž teoretické hustoty.



Obrázek 12: Porovnání proložených hustot.



Obrázek 13: Porovnání teoretických hustot.

Z histogramů a vykreslených proložených hustot si lze povšimnout, že téměř všechny odhady jsou nestranné a jejich střední hodnota je přibližně rovna 0. Pouze odhad pomocí LMSE, který využívá měření \mathbf{z} , a jehož počáteční střední hodnota $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$, je stranný. Střední hodnota odhadu je v tomto případě rovna 2.5, což koresponduje s teoretickou částí. Co se týče variancí, tak ty jsou téměř ve všech případech téměř totožné. Pouze v případě metody LMSE (měření \mathbf{z}) s falešným parametrem $R = \frac{1}{4}$ dojde ke značnému rozdílu mezi teoretickou variancí a variancí získanou pomocí simulace. Hodnoty prvních dvou momentů získaných ze simulace byly zaneseny do následující tabulky:

	$E[\tilde{\mathbf{x}}]$	$\text{var}[\tilde{\mathbf{x}}]$
ML: \mathbf{z}	0.0202	1.0203
LMSE: \mathbf{z}_0	0.0205	0.5151
LMSE: \mathbf{z}_1	0.0035	0.4892
LMSE: \mathbf{z}	0.0091	0.3366
LMSE: $\mathbf{z}; R = \frac{1}{4}$	0.0136	0.4916
LMSE: $\mathbf{z}; R = 4$	0.0098	0.4271
LMSE: $\mathbf{z}; \bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$	2.5091	0.3366

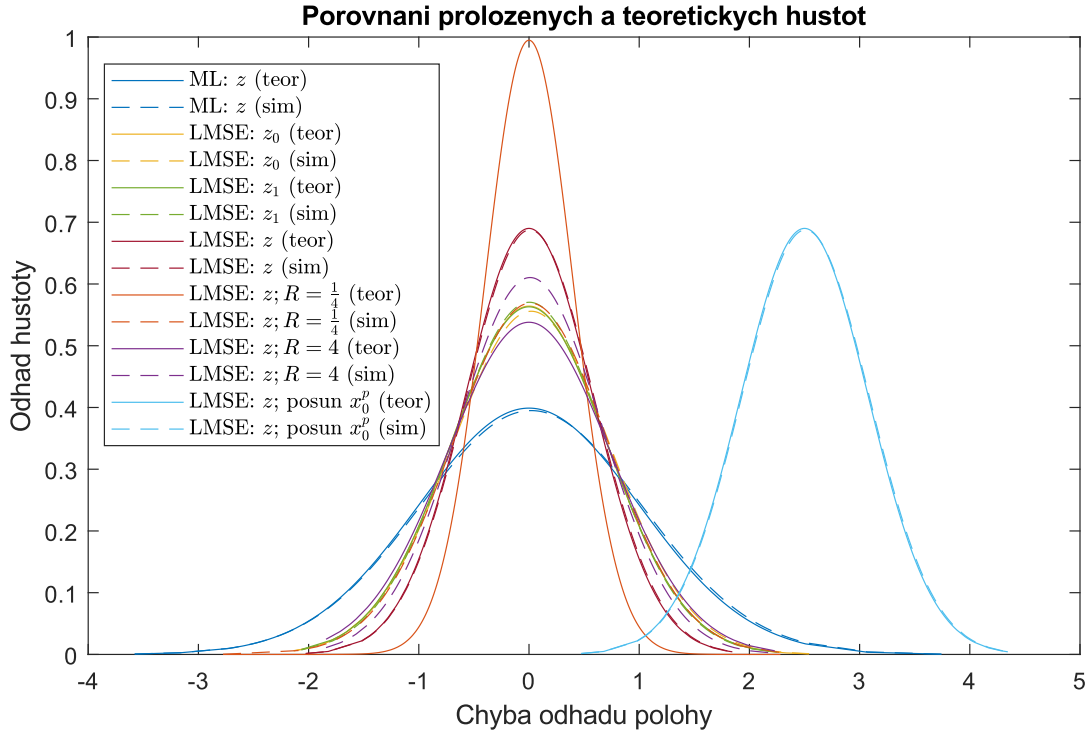
Tabulka 1: Tabulka s hodnotami středních hodnot a variancemi proložených hustot odhadů.

Do další tabulky byly zaneseny teoretické hodnoty prvních dvou momentů.

	$E[\tilde{\mathbf{x}}]$	$\text{var}[\tilde{\mathbf{x}}] = \mathbf{P}_{\tilde{\mathbf{x}}}(\text{pozice } 1,1)$
ML: \mathbf{z}	0	1
LMSE: \mathbf{z}_0	0	$\frac{1}{2}$
LMSE: \mathbf{z}_1	0	$\frac{121}{241} \doteq 0.5021$
LMSE: \mathbf{z}	0	$\frac{121}{362} \doteq 0.3343$
LMSE: $\mathbf{z}; R = \frac{1}{4}$	0	$\frac{197}{1225} \doteq 0.1608$
LMSE: $\mathbf{z}; R = 4$	0	$\frac{844}{1535} \doteq 0.5498$
LMSE: $\mathbf{z}; \bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$	2.5	$\frac{121}{362} \doteq 0.3343$

Tabulka 2: Tabulka s hodnotami středních hodnot a variancemi teoretických hustot odhadů.

Na závěr byly mezi sebou porovnány proložené a teoretické hustoty.



Obrázek 14: Vzájemné porovnání teoretických a proložených hustot.

Lze si povšimnout, že téměř ve všech případech se simulace shoduje s teorií, jelikož teoretické střední hodnoty a k nim příslušné střední hodnoty, získané pomocí simulace, jsou téměř ekvivalentní. To samé lze prohlásit i o varianci. Pouze pro případ LMSE (měření z) s falešným parametrem $R = \frac{1}{4}$ dojde k většímu rozporu mezi teorií a simulací.

3 Závěr

Tématem této semestrální práce byl optimální odhad náhodné proměnné. Hlavním cílem bylo na základě měření a modelu systému odhadnout neznámou počáteční polohu a rychlost objektu, se známou apriorní informací ve formě náhodné veličiny. Pro stanovení odhadů byly v této semestrální práci použity metody odhadu ve smyslu ML a LMSE za použití prvních několika měření.

Nejprve byla zadaná apriorní informace ignorována a byl navržen odhad $\hat{\mathbf{x}}_0$ ve smyslu maximální věrohodnosti (ML). V další části již byla znalost apriorní informace využita a byl určen nejlepší lineární odhad ve smyslu střední kvadratické chyby při použití různých měření. Následně byly vyjádřeny kovarianční matice chyb odhadů pro všechny případy. Bylo si možné povšimnout, že v případě odhadu ve smyslu LMSE se příslušné kovarianční matice odhadů a kovarianční matice chyb odhadů mezi sebou lišily. V dalším kroku jsme zkoumali, co se stane, pokud bude estimátor navržen za špatné znalosti parametrů systému. Na závěr teoretické části byly, stejně jako v minulé semestrální práci, vykresleny 3σ elipsy odpovídající chybám odhadů.

Druhá část této semestrální práce se týkala simulačních úloh. Nejprve bylo vygenerováno 1000 simulací vektoru $[\mathbf{x}_0^T, \mathbf{z}^T]^T$. Poté byly, pro každý vektor, dopočteny realizace odhadů $\hat{\mathbf{x}}_0$ a chyby odhadů $\tilde{\mathbf{x}}_0 = \mathbf{x}_0 - \hat{\mathbf{x}}_0$. Na základě toho byly následně odhadnuty hustoty chyb jednotlivých odhadů polohy pomocí normalizovaných histogramů, které byly porovnány mezi sebou. Získané histogramy byly proloženy, pomocí techniky přiřazení momentů, gaussovskými hustotami. Na závěr byly proložené hustoty porovnány s teoretickými.

A Zdrojový kód z Matlabu

```
1  clc
2  close all
3  clear all
4
5  %% Semestrální práce c. 2 – TOD
6  % Jan Burian
7
8  %% I. Teoretická část
9  % Zadání systému
10 %  $x_{k+1} = Fx_k + Gw_k, w_k \sim N(0, Q)$ 
11 %  $z_k = Hx_k + v_k, v_k \sim N(0, R)$ 
12
13 %% Úkol (i)
14 % Parametry systému
15 syms T R real
16 q = 0.1;
17 F = [1 T;
18      0 1];
19 G = 1;
20 H = [1 0];
21 Q = q * [T^3/3    T^2/2;
22          T^2/2    T];
23 R = 1;
24 %% Metoda maximální verohodnosti pro měření  $z_0, z_1$ 
25 H = [1 0; 1 T];
26 sigma = [R 0; 0 (q*(T^3)/3 + R)];
27
28 ML_odhad = inv(H' * inv(sigma) * H) * H' * inv(sigma);
29 ML_odhad_subs = subs(ML_odhad, T, 1);
30
31 % kovarianční matice (chyby) odhadu
32 cov_odhad_ML = inv(H' * inv(sigma) * H);
33 cov_odhad_ML_subs = subs(cov_odhad_ML, T, 1);
34
35 %% Lineární odhady ve smyslu střední kvadratické chyby pro jednotlivá
    měření
36 % měření  $z_0$ 
37 syms x_poloha x_rychlost z0
38 x_odhad = [x_poloha; x_rychlost];
39 H_z0 = [1 0];
40 R_z0 = R;
41 Px = [1 1; 1 4];
42
43 P_x_z0 = Px * H_z0';
44 P_z0 = H_z0 * Px * H_z0' + R_z0;
45 E_z0 = H_z0 * x_odhad;
46
47 LMSE_odhad_z0 = x_odhad + P_x_z0 * inv(P_z0) * (z0 - E_z0);
48
49 % měření  $z_1$ 
50 syms x_poloha x_rychlost z1
```

```

51 T = 1;
52
53 x_odhad = [x_poloha; x_rychlost];
54 H_z1 = [1 T];
55 R_z1 = R + q*((T^3)/3);
56 Px = [1 1; 1 4];
57
58 P_x_z1 = Px * H_z1';
59 P_z1 = H_z1 * Px * H_z1' + R_z1;
60 E_z1 = H_z1 * x_odhad;
61
62 LMSE_odhad_z1 = x_odhad + P_x_z1 * inv(P_z1) * (z1 - E_z1);
63
64 % mereni z = [z0; z1]
65 syms x_poloha x_rychlost z0 z1
66 x_odhad = [x_poloha; x_rychlost];
67 H_z = [1 0; 1 1];
68 R_z = [R 0; 0 R + q*((T^3)/3)];
69 Px = [1 1; 1 4];
70
71 P_x_z = Px * H_z';
72 P_z = H_z * Px * H_z' + R_z;
73 E_z = H_z * x_odhad;
74
75 LMSE_odhad_z = x_odhad + P_x_z * inv(P_z) * ([z0; z1] - E_z);
76
77 %% Miry duvery (kovariancni matice chyb odhadu)
78 format rational
79 % mereni z0
80 P_z0_x = H_z0*Px;
81 mira_duvery_z0 = Px - P_x_z0 * inv(P_z0) * P_z0_x;
82
83 % mereni z1
84 P_z1_x = H_z1*Px;
85 mira_duvery_z1 = Px - P_x_z1 * inv(P_z1) * P_z1_x;
86
87 % mereni z
88 P_z_x = H_z*Px;
89 mira_duvery_z = Px - P_x_z * inv(P_z) * P_z_x;
90
91 %% Kovariancni matice odhadu
92 cov_LMSE_z0 = P_x_z0 * inv(P_z0) * P_z0_x;
93 cov_LMSE_z1 = P_x_z1 * inv(P_z1) * P_z1_x;
94 cov_LMSE_z = P_x_z * inv(P_z) * P_z_x;
95
96 %% Navrzeni estimatoru se spatnymi parametry
97 % R = 1/4
98 clear R
99 R = 1/4;
100 syms x_poloha x_rychlost z0 z1
101 x_odhad = [x_poloha; x_rychlost];
102 H_z = [1 0; 1 1];
103 R_z_wrong_1 = [R 0; 0 R + q*((T^3)/3)];

```

```

104 Px = [1 1; 1 4];
105
106 P_x_z = Px * H_z';
107 P_z_wrong_R_1 = H_z * Px * H_z' + R_z_wrong_1;
108 E_z = H_z * x_odhad;
109
110 LMSE_odhad_z_wrong_R_1 = x_odhad + P_x_z * inv(P_z_wrong_R_1) * ([z0; z1]
    - E_z);
111
112 % R = 4
113 clear R
114 R = 4;
115 syms x_poloha x_rychlost z0 z1
116 x_odhad = [x_poloha; x_rychlost];
117 H_z = [1 0; 1 1];
118 R_z_wrong_2 = [R 0; 0 R + q*((T^3)/3)];
119 Px = [1 1; 1 4];
120
121 P_x_z = Px * H_z';
122 P_z_wrong_R_2 = H_z * Px * H_z' + R_z_wrong_2;
123 E_z = H_z * x_odhad;
124
125 LMSE_odhad_z_wrong_R_2 = x_odhad + P_x_z * inv(P_z_wrong_R_2) * ([z0; z1]
    - E_z);
126
127 % x0^p := x0^p - 5
128 clear R
129 R = 1;
130 x_odhad = [x_poloha-5; x_rychlost];
131 H_z = [1 0; 1 1];
132 R_z = [R 0; 0 R + q*((T^3)/3)];
133 Px = [1 1; 1 4];
134
135 P_x_z = Px * H_z';
136 P_z = H_z * Px * H_z' + R_z;
137 E_z = H_z * x_odhad;
138
139 LMSE_odhad_z_posun_x_poloha = x_odhad + P_x_z * inv(P_z) * ([z0; z1] -
    E_z);
140
141 %% Strannost odhadu
142 E_x = [x_poloha; x_rychlost];
143 E_x_odhad = [x_poloha-5; x_rychlost]; % odhad s posunutou polohou o -5
144
145 strannost = E_x - E_x_odhad - P_x_z * inv(P_z) * H_z * E_x + P_x_z * inv(
    P_z) * H_z * E_x_odhad;
146
147 %% Miry duvery (kovariancni matice chyby odhadu) - nespravne parametry
148 format rational
149 % R = 1/4
150 mira_duvery_wrong_R_1 = Px - P_x_z * inv(P_z_wrong_R_1) * P_z_x;
151
152 % R = 4

```



```

153 mira_duvery_wrong_R_2 = Px - P_x_z * inv(P_z_wrong_R_2) * P_z_x;
154
155 % x0^p := x0^p - 5
156 mira_duvery_posun_x_poloha = Px - P_x_z * inv(P_z) * P_z_x;
157
158 %% Vykresleni elips pro kovariancni matice chyb odhadu
159 x0 = [0; 0];
160 t = 0:0.01:2*pi;
161
162 x = sin(t);
163 y = cos(t);
164
165 vector_xy = [x; y];
166 xy = zeros(2, length(t));
167
168 cells_cov = cell(1,4);
169 cells_cov{1} = cov_odhad_ML_subs;
170 cells_cov{2} = mira_duvery_z0;
171 cells_cov{3} = mira_duvery_z1;
172 cells_cov{4} = mira_duvery_z;
173
174 figure;
175 for i = 1:length(cells_cov)
176     S = cells_cov{i};
177     P = chol(S, 'lower');
178     for j = 1:length(t)
179         xy(:,j) = x0 + 3 * P * vector_xy(:,j);
180     end
181     plot(xy(1,:), xy(2,:));
182     hold on;
183 end
184 scatter(x0(1), x0(2), '+', 'k');
185
186 title('3-\sigma elipsy odhadu - ML a LMSE');
187 xlabel('Odhad polohy');
188 ylabel('Odhad rychlosti');
189 legend('ML: $$$', 'LMSE: $_0$', 'LMSE: $_1$', 'LMSE: $$$', 'Interpreter',
190         , 'latex')
191 grid on;
192
193 %% Vykresleni elips pro kovariancni matice chyb odhadu zalozene na nespr.
194     hodnotach parametru
195 cells_cov = cell(1,4);
196 cells_cov{1} = mira_duvery_z;
197 cells_cov{2} = mira_duvery_wrong_R_1;
198 cells_cov{3} = mira_duvery_wrong_R_2;
199 cells_cov{4} = mira_duvery_posun_x_poloha;
200
201 figure;
202 for i = 1:length(cells_cov)
203     S = cells_cov{i};
204     P = chol(S, 'lower');
205     if i == 4

```

```

204     x0 = [2.5; -2.5];
205     for j = 1:length(t)
206         xy(:,j) = x0 + 3 * P * vector_xy(:,j);
207     end
208     plot(xy(1,:), xy(2,:));
209     scatter(x0(1), x0(2), '+', 'k');
210     hold on;
211 else
212     x0 = [0; 0];
213     for j = 1:length(t)
214         xy(:,j) = x0 + 3 * P * vector_xy(:,j);
215     end
216     plot(xy(1,:), xy(2,:));
217     hold on;
218 end
219 end
220 scatter(0, 0, '+', 'k');
221
222 title('3-\sigma elipsy odhadu LMSE (falesne a skutečne parametry)');
223 xlabel('Odhad polohy');
224 ylabel('Odhad rychlosti');
225 legend('LMSE: $z$', 'LMSE: $R = \frac{1}{4}$', 'LMSE: $R = 4$', 'LMSE:
    $x_0^p = x_0^p - 5$', 'Interpreter', 'latex')
226 grid on;
227
228
229 %% II. Simulacni cast
230 % Parametry
231 T = 1;
232 Px = [1 1;
233       1 4];
234 q = 0.1;
235 Q = q * [T^3/3    T^2/2;
236          T^2/2    T];
237 R = 1;
238 x0 = [0; 0]; % pocatecni podminka – radek = vektor x, sloupec =k, hloubka
    = iterace
239
240 F = [1 T;
241      0 1];
242 H = [1 0];
243
244 %% Definice promennych
245 pocet_simulaci = 1000;
246 Z = zeros(2, pocet_simulaci); % radek = k, sloupec = iterace
247
248 % Odhady
249 odhad_ML_z = zeros(2,pocet_simulaci);
250
251 odhad_LMSE_z0 = zeros(2,pocet_simulaci);
252 odhad_LMSE_z1 = zeros(2,pocet_simulaci);
253 odhad_LMSE_z = zeros(2,pocet_simulaci);
254

```

```

255 odhad_LMSE_z_wrong_R_1 = zeros(2,pocet_simulaci);
256 odhad_LMSE_z_wrong_R_2 = zeros(2,pocet_simulaci);
257 odhad_LMSE_z_posun_x_poloha = zeros(2,pocet_simulaci);
258
259 % Chyby odhadu
260 chyba_odhadu_ML_z = zeros(2,pocet_simulaci);
261
262 chyba_odhadu_LMSE_z0 = zeros(2,pocet_simulaci);
263 chyba_odhadu_LMSE_z1 = zeros(2,pocet_simulaci);
264 chyba_odhadu_LMSE_z = zeros(2,pocet_simulaci);
265
266 chyba_odhadu_LMSE_z_wrong_R_1 = zeros(2,pocet_simulaci);
267 chyba_odhadu_LMSE_z_wrong_R_2 = zeros(2,pocet_simulaci);
268 chyba_odhadu_LMSE_z_posun_x_poloha = zeros(2,pocet_simulaci);
269
270 %% Generovani simulaci vektoru
271 for i = 1:pocet_simulaci
272     X(:,1,i) = x0 + (randn(1,2) * chol(Px))'; % x0
273     Z(1,i) = H * X(:,1,i) + randn * sqrt(R); % z0 = Hx0 + v0
274
275     X(:,2,i) = F * X(:,1,i) + (randn(1,2) * chol(Q))'; % x1 = Fx0 + w0
276     Z(2,i) = H * X(:,2,i) + randn * sqrt(R); % z1 = Hx1 + v1
277
278     % Odhady
279     odhad_ML_z(:,i) = [1 0; -1 1] * Z([1,2],i);
280
281     odhad_LMSE_z0(:,i) = [x0(1)/2 + Z(1,i)/2; x0(2) - x0(1)/2 + Z(1,i)
        /2];
282     odhad_LMSE_z1(:,i) = 1/241 * [181*x0(1) - 60*x0(2) + 60*Z(2,i); 91*x0
        (2) - 150*x0(1) + 150*Z(2,i)];
283     odhad_LMSE_z(:,i) = 1/362 * [181*x0(1) - 60*x0(2) + 121*Z(1,i) + 60*Z
        (2,i); 122*x0(2) - 181*x0(1) - 59*Z(1,i) + 240*Z(2,i)];
284
285     odhad_LMSE_z_wrong_R_1(:,i) = 1/1225 * [317*x0(1) - 120*x0(2) + 788*Z
        (1,i) + 120*Z(2,i); 205*x0(2) - 368*x0(1) - 652*Z(1,i) + 1020*Z(2,
        i)];
286     odhad_LMSE_z_wrong_R_2(:,i) = 1/1535 * [1084*x0(1) - 240*x0(2) + 211*
        Z(1,i) + 240*Z(2,i); 845*x0(2) - 721*x0(1) + 31*Z(1,i) + 690*Z(2,i)
        ];
287     odhad_LMSE_z_posun_x_poloha(:,i) = 1/362 * [181*x0(1) - 60*x0(2) +
        121*Z(1,i) + 60*Z(2,i) - 905; 122*x0(2) - 181*x0(1) - 59*Z(1,i) +
        240*Z(2,i) + 905];
288
289 % Vypocet chyb odhadu
290 chyba_odhadu_ML_z(:,i) = X(:,1,i) - odhad_ML_z(:,i);
291 chyba_odhadu_LMSE_z0(:,i) = X(:,1,i) - odhad_LMSE_z0(:,i);
292 chyba_odhadu_LMSE_z1(:,i) = X(:,1,i) - odhad_LMSE_z1(:,i);
293 chyba_odhadu_LMSE_z(:,i) = X(:,1,i) - odhad_LMSE_z(:,i);
294 chyba_odhadu_LMSE_z_wrong_R_1(:,i) = X(:,1,i) -
        odhad_LMSE_z_wrong_R_1(:,i);
295 chyba_odhadu_LMSE_z_wrong_R_2(:,i) = X(:,1,i) -
        odhad_LMSE_z_wrong_R_2(:,i);

```

```

296     chyba_odhadu_LMSE_z_posun_x_poloha(:, i) = X(:, 1, i) -
        odhad_LMSE_z_posun_x_poloha(:, i);
297 end
298
299 chyby_odhadu = cell(1, 7);
300 chyby_odhadu{1} = chyba_odhadu_ML_z;
301 chyby_odhadu{2} = chyba_odhadu_LMSE_z0;
302 chyby_odhadu{3} = chyba_odhadu_LMSE_z1;
303 chyby_odhadu{4} = chyba_odhadu_LMSE_z;
304 chyby_odhadu{5} = chyba_odhadu_LMSE_z_wrong_R_1;
305 chyby_odhadu{6} = chyba_odhadu_LMSE_z_wrong_R_2;
306 chyby_odhadu{7} = chyba_odhadu_LMSE_z_posun_x_poloha;
307
308 %% Histogramy
309 nbins = 30;
310 titles = ["ML:  $z$ ", "LMSE:  $z_0$ ", "LMSE:  $z_1$ ", "LMSE:  $z$ ", "LMSE:  $z$ 
        ;  $R = \frac{1}{4}$ ", "LMSE:  $z$ ;  $R = 4$ ", "LMSE:  $z$ ;  $x_0^p = x_0^p$ 
        } - 5"];
311 for i = 1:length(chyby_odhadu)
312     chyba_odhadu = chyby_odhadu{i};
313     figure;
314     histogram(chyba_odhadu(1,:), nbins, 'Normalization', 'pdf');
315     xlabel('Chyba odhadu polohy');
316     ylabel('Odhad hustoty');
317     title(titles(i), 'Interpreter', 'latex');
318 end
319
320 figure;
321 for j = 1:length(chyby_odhadu)
322     chyba_odhadu = chyby_odhadu{j};
323     subplot(4, 2, j)
324     histogram(chyba_odhadu(1,:), nbins, 'Normalization', 'pdf')
325     xlabel('Chyba odhadu polohy');
326     ylabel('Odhad hustoty')
327     title(titles(j), 'Interpreter', 'latex');
328     xlim([-3 5])
329     ylim([0 0.8])
330 end
331
332 %% Teoreticke Gaussovy krivky pro jednotlivé případy
333 var_ML_z = cov_odhad_ML_subs(1, 1);
334 var_LMSE_z0 = mira_duvery_z0(1, 1);
335 var_LMSE_z1 = mira_duvery_z1(1, 1);
336 var_LMSE_z = mira_duvery_z(1, 1);
337 var_LMSE_z_wrong_R_1 = mira_duvery_wrong_R_1(1, 1);
338 var_LMSE_z_wrong_R_2 = mira_duvery_wrong_R_2(1, 1);
339 var_LMSE_z_posun_x_poloha = mira_duvery_posun_x_poloha(1, 1);
340
341 cell_varis = cell(1, 7);
342 cell_varis{1} = var_ML_z;
343 cell_varis{2} = var_LMSE_z0;
344 cell_varis{3} = var_LMSE_z1;
345 cell_varis{4} = var_LMSE_z;

```

```

346 cell_varis{5} = var_LMSE_z_wrong_R_1;
347 cell_varis{6} = var_LMSE_z_wrong_R_2;
348 cell_varis{7} = var_LMSE_z_posun_x_poloha;
349
350 mean_teo = [0 0 0 0 0 0 2.5];
351 cell_y_teo = cell(1,7);
352 figure;
353 for j = 1:length(chyby_odhadu)
354     chyba_odhadu = chyby_odhadu{j};
355     variance = cell_varis{j};
356     y_teo = normpdf(sort(chyba_odhadu(1,:)), mean_teo(j), sqrt(variance))
357     ;
358     cell_y_teo{j} = y_teo;
359     plot(sort(chyba_odhadu(1,:)), y_teo);
360     hold on;
361 end
362 title("Porovnani teoretickych hustot");
363 xlabel('Chyba odhadu polohy');
364 ylabel('Odhad hustoty');
365 legend(titles, 'Interpreter', 'latex')
366
367 %% Gaussovy krivky ze simulace pro jednotlive pripady
368 cell_y_sim = cell(1,7);
369 for i = 1:length(chyby_odhadu)
370     chyba_odhadu = chyby_odhadu{i};
371     y_sim = normpdf(sort(chyba_odhadu(1,:)), mean(chyba_odhadu(1,:)),
372         sqrt(var(chyba_odhadu(1,:))));
373     cell_y_sim{i} = y_sim;
374 end
375
376 %% Variance ze simulace
377 for u = 1:length(chyby_odhadu)
378     chyba_odhadu = chyby_odhadu{u};
379     variance_test = var(chyba_odhadu(1,:));
380 end
381
382 %% Porovnani jednotlivych krivek mezi sebou
383 for j = 1:length(chyby_odhadu)
384     chyba_odhadu = chyby_odhadu{j};
385     figure;
386     plot(sort(chyba_odhadu(1,:)), cell_y_teo{j});
387     hold on;
388     plot(sort(chyba_odhadu(1,:)), cell_y_sim{j});
389 end
390
391 %% Porovnani prolozenych Gaussovych krivek mezi sebou
392 figure;
393 for j = 1:length(chyby_odhadu)
394     chyba_odhadu = chyby_odhadu{j};
395     plot(sort(chyba_odhadu(1,:)), cell_y_sim{j});
396     hold on;
397 end
398 title("Porovnani prolozenych hustot");

```

```

397 xlabel('Chyba odhadu polohy');
398 ylabel('Odhad hustoty');
399 legend(titles, 'Interpreter', 'latex')
400 ylim([0 1])
401
402 %% Gaussovy krivky (metoda prirazeni momentu) a histogramy
403 %titles = ["ML (mereni z)", "LMSE (mereni z_0)", "LMSE (mereni z_1)", "
    LMSE (mereni z)", "LMSE (mereni z s parametrem R = 1/4)", "LMSE (
    mereni z s parametrem R = 4)", "LMSE (mereni z s posunutym parametrem
    x_0^{poloha})"];
404 for i = 1:length(chyby_odhadu)
405     figure;
406     chyba_odhadu = chyby_odhadu{i};
407     y_sim = cell_y_sim{i};
408     plot(sort(chyba_odhadu(1,:)), y_sim, 'LineWidth', 1.5);
409     hold on;
410     histogram(chyba_odhadu(1,:), nbins, 'Normalization','pdf');
411     xlabel('Chyba odhadu polohy');
412     ylabel('Odhad hustoty');
413     title(titles(i), 'Interpreter', 'latex');
414 end
415
416 %% Celkove porovnani krivek (prolozene a teoreticke)
417 figure;
418 for i = 1:length(chyby_odhadu)
419     chyba_odhadu = chyby_odhadu{i};
420     p = plot(sort(chyba_odhadu(1,:)), cell_y_teo{i});
421     c = p.Color;
422     hold on
423     plot(sort(chyba_odhadu(1,:)), cell_y_sim{i}, '—', 'Color', c);
424     hold on
425 end
426
427 legend('ML: $z$ (teor)', 'ML: $z$ (sim)', 'LMSE: $z_0$ (teor)', 'LMSE:
    $z_0$ (sim)', 'LMSE: $z_1$ (teor)', 'LMSE: $z_1$ (sim)', 'LMSE: $z$ (
    teor)', 'LMSE: $z$ (sim)', 'LMSE: $z; R = \frac{1}{4}$ (teor)', 'LMSE:
    $z; R = \frac{1}{4}$ (sim)', 'LMSE: $z; R = 4$ (teor)', 'LMSE: $z; R
    = 4$ (sim)', 'LMSE: $z$; posun $x_0^p$ (teor)', 'LMSE: $z$; posun
    $x_0^p$ (sim)', 'Interpreter', 'latex')
428 title("Porovnani prolozenych a teoretickyh hustot");
429 xlabel('Chyba odhadu polohy');
430 ylabel('Odhad hustoty');
431
432 %% Histogramy
433 figure
434 for i = 1:length(chyby_odhadu)
435     chyba_odhadu = chyby_odhadu{i};
436     histogram(chyba_odhadu(1,:), nbins, 'Normalization','pdf', '
        DisplayStyle', 'stairs');
437     %histogram(chyba_odhadu(1,:), nbins, 'Normalization','pdf');
438     hold on
439     xlabel('Chyba odhadu polohy');
440     ylabel('Odhad hustoty');

```

```

441 end
442 legend("ML: $z$", "LMSE: $z_0$", "LMSE: $z_1$", "LMSE: $z$", "LMSE: $z; R$
      = \frac{1}{4}$", "LMSE: $z; R = 4$", "LMSE: $z; $x_0^{p} = x_0^{p} -
      5$", 'Location', 'northwest', 'Interpreter', 'latex');
443 title("Porovnani jednotlivych histogramu");
444
445 %% Stredni hodnoty a variance ze simulace
446 result_means = zeros(1,7);
447 result_varis = zeros(1,7);
448
449 for i = 1:length(chyby_odhadu)
450     chyba_odhadu = chyby_odhadu{i};
451     result_means(1, i) = mean(chyba_odhadu(1,:));
452     result_varis(1, i) = var(chyba_odhadu(1,:));
453 end

```

Seznam obrázků

1	Vykreslení $3\text{-}\sigma$ elips, které odpovídají chybám odhadů, kde $E[\mathbf{x}_0] = [00]$	11
2	Vykreslení $3\text{-}\sigma$ elips, které odpovídají kovariančním maticím chyb s falešnými parametry, společně s $3\text{-}\sigma$ elipsou odpovídající skutečné kovarianční matici chyby odhadu LMSE: \mathbf{z}	12
3	Normalizovaný histogram proložený hustotou pro metodu ML (měření \mathbf{z}).	13
4	Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z_0).	13
5	Normalizovaný histogram proložený hustotou pro metodu LMSE (měření z_1).	14
6	Normalizovaný histogram proložený hustotou pro metodu LMSE (měření \mathbf{z}).	14
7	Normalizovaný histogram proložený hustotou pro metodu LMSE (měření \mathbf{z}) s falešným parametrem $R = \frac{1}{4}$	15
8	Normalizovaný histogram proložený hustotou pro metodu LMSE (měření \mathbf{z}) s falešným parametrem $R = 4$	15
9	Normalizovaný histogram proložený hustotou pro metodu LMSE (měření \mathbf{z}) s počáteční střední hodnotu $\bar{x}_0^{\text{poloha}} := \bar{x}_0^{\text{poloha}} - 5$	16
10	Porovnání obrysů jednotlivých normalizovaných histogramů.	16
11	Porovnání normalizovaných histogramů pomocí <i>subplotu</i>	17
12	Porovnání proložených hustot.	18
13	Porovnání teoretických hustot.	18
14	Vzájemné porovnání teoretických a proložených hustot.	20