

Západočeská univerzita v Plzni  
Fakulta aplikovaných věd  
Katedra kybernetiky



# SEMESTRÁLNÍ PRÁCE Č. 3

TEORIE ODHADU A ZPRACOVÁNÍ SIGNÁLŮ  
ZKRATKA KATEDRY/ZKRATKA PŘEDMĚTU (KKY/TOD)

Jan Burian  
30. listopadu 2022

# Obsah

<b>1</b>	<b>Zadání</b>	<b>3</b>
<b>2</b>	<b>Vypracování</b>	<b>4</b>
2.1	Úkol (i) . . . . .	4
2.1.1	Optimální deterministický rekonstruktor stavu . . . . .	4
2.1.2	Kalmanův filtr . . . . .	5
2.1.3	Ustálený Kalmanův filtr . . . . .	5
2.2	Úkol (ii) . . . . .	6
2.3	Úkol (iii) . . . . .	8
2.4	Úkol (iv) . . . . .	10
2.4.1	Optimální deterministický rekonstruktor stavu . . . . .	10
2.4.2	Kalmanův filtr . . . . .	10
2.4.3	Ustálený Kalmanův filtr . . . . .	11
2.4.4	Vykreslení . . . . .	11
<b>3</b>	<b>Závěr</b>	<b>13</b>

## Odhad stavu lineárního systému

### Zadání semestrální práce č. 3

Uvažujme objekt, který se pohybuje po přímce s náhodným zrychlením, zatímco je s konstantní periodou  $T$  měřena jeho poloha. Cílem je na základě měření a modelu systému rekurzivně odhadovat náhodný stav systému, v našem případě polohu a rychlost objektu. V diskrétním případě můžeme uvažovat lineární dynamický systém s popisem

$$\begin{aligned} \mathbf{x}_{k+1} &= \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} \mathbf{x}_k + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N} \left( \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \frac{1}{40} \begin{bmatrix} \frac{T^3}{2} & \frac{T^2}{2} \\ \frac{T^2}{2} & T \end{bmatrix} \right), \quad \mathbf{x}_0 \sim \mathcal{N} \left( \begin{bmatrix} 10 \\ 1 \end{bmatrix}, \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix} \right), \\ z_k &= \begin{bmatrix} 1 & 0 \end{bmatrix} \mathbf{x}_k + v_k, \quad v_k \sim \mathcal{N}(0, 10), \end{aligned}$$

kde vzorkovací perioda je  $T = 1$  a procesy  $[\mathbf{w}_k]_{k=1}^{+\infty}$  a  $[v_k]_{k=1}^{+\infty}$  jsou vzájemně nezávislé bílé šумы, nezávislé na počátečním stavu  $\mathbf{x}_0$ .

**Úkoly:** Rekonstruktor v porovnání s odhadem náhodného stavu Kalmanovým filtrem. Vygenerujte 1000 trajektorií stavu a měření pro  $k = 0, \dots, 25$ .

- (i) Pro porovnání nejprve ignorujte, že systém je stochastický, a navrhnete pro něj optimální rekonstruktor – navrhnete zisk  $\mathbf{K}$  pro filtr ve tvaru  $\hat{\mathbf{x}}_k = (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{F}\hat{\mathbf{x}}_{k-1} + \mathbf{K}\mathbf{z}_k$  přiřazením pólů do nuly. V jakém smyslu je rekonstruktor optimální? Následně stochastický charakter systému vezměte v potaz a formulujte problém odhadu náhodného stavu pomocí Kalmanova filtru. Nakonec určete ustálenou hodnotu Kalmanova zisku  $\mathbf{K}_\infty$ . Pro každou trajektorii měření odhadněte stav pomocí:
    - (a) optimálního deterministického rekonstruktoru stavu,
    - (b) ustáleného Kalmanova filtru, tj. filtru s konstantním ziskem  $\mathbf{K}_\infty$ ,
    - (c) Kalmanova filtru.
  - (ii) Vykreslete první trajektorii stavu a porovnejte ji s příslušnými filtračními odhady a měřeními. Pro první trajektorii dále vykreslete chyby filtračních odhadů. Lze něco říci jen z první trajektorie?
  - (iii) V případě (b) a (c) lze analyzovat inovační posloupnost, která musí splňovat určité vlastnosti. Ty lze monitorovat a brát jako nutnou podmínku správného chodu filtru. Pro oba filtry proto porovnejte následující ukazatele a zamyslete se, jestli vše funguje, jak má;
    - odhady středních hodnot inovací ve všech časech — v grafu,
    - odhady variancí inovací pro  $k = 0, 1, 5, 25$  i kovariancí mezi těmito časy — v tabulce.
  - (iv) Když provádíte simulaci, máte přístup ke skutečnému stavu. Proto můžete vyhodnotit kvalitu odhadů přímo z pohledu střední kvadratické chyby. Odhadněte tedy střední hodnoty kvadratických chyb všech filtračních odhadů v závislosti na čase a získané křivky porovnejte s teoretickými hodnotami. Lze algoritmy (a), (b) a (c) uspořádat od nejlepšího po nejhorší?
- Nápověda: Pro porovnání simulace s teorií budete potřebovat kovarianční matice chyby: vývoj stopy filtrační kovarianční matice. Můžete využít Josephovu formu.

## 2 Vypracování

Semestrální práce byla z velké části řešena v programovém prostředí Matlab.

### 2.1 Úkol (i)

V první řadě byl zadáný systém nejprve přepsán do následujícího tvaru:

$$\mathbf{x}_{k+1} = \mathbf{F}\mathbf{x}_k + \mathbf{G}\mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}), \quad (1)$$

$$\mathbf{z}_k = \mathbf{H}\mathbf{x}_k + v_k, \quad v_k \sim \mathcal{N}(0, R), \quad (2)$$

kde  $\mathbf{F} = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}$ ,  $\mathbf{G} = I$ ,  $\mathbf{Q} = \frac{1}{40} \begin{bmatrix} \frac{T^3}{3} & \frac{T^2}{2} \\ \frac{T^2}{2} & T \end{bmatrix}$ ,  $\mathbf{H} = [1 \quad 0]$  a  $R = 10$ .

Ze zadání je dále známo, že  $T = 1$  a náhodné veličiny  $\mathbf{w}_k$  a  $v_k$  jsou vzájemně nezávislé bílé šumy  $\forall k \in \mathbb{N}$ .

Dále známe střední hodnotu a kovarianční matici počátečního stavu  $\mathbf{x}_0$ ;  $\mathbf{x}_0 \sim \mathcal{N}\left(\begin{bmatrix} 10 \\ 1 \end{bmatrix}, \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix}\right)$ .

Následně již bylo možné vygenerovat 1000 trajektorií stavu a měření pro  $k = 0, \dots, 25$ . Postup generování byl podobný jako v minulé semestrální práci.

#### 2.1.1 Optimální deterministický rekonstruktor stavu

Nyní jsme schopni navrhnout optimální rekonstruktor. Navrhne zisk  $\mathbf{K}$  pro filtr v následujícím tvaru:

$$\hat{\mathbf{x}}_{k+1} = (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{F}\hat{\mathbf{x}}_k + \mathbf{K}\mathbf{z}_{k+1}, \quad (3)$$

a to přiřazením pólů do nuly.

Tohoto požadavku docílíme vyřešením rovnice pro získání nulových vlastních čísel charakteristického polynomu matice  $(\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{F}$ . Dostaneme tedy následující rovnici:

$$\det[\lambda\mathbf{I} - (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{F}] = 0 \quad (4)$$

Po dosazení do rovnice (4) dostaneme:

$$\lambda^2 + (k_1 + k_2 - 2)\lambda + (1 - k_1) = 0 \quad (5)$$

Pro zjištění  $k_1$  a  $k_2$  dostaneme soustavu dvou rovnic o dvou neznámých:

$$\begin{cases} k_1 + k_2 - 2 = 0 \\ 1 - k_1 = 0 \end{cases} \quad (6)$$

Po vyřešení soustavy rovnic (6) dostaneme:

$$\mathbf{K} = \begin{bmatrix} k_1 \\ k_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad (7)$$

Nyní můžeme definovat odhad stavu pomocí optimálního rekonstruktoru:

$$\hat{\mathbf{x}}_{k+1} = \begin{bmatrix} 0 & 0 \\ -1 & 0 \end{bmatrix} \hat{\mathbf{x}}_k + \begin{bmatrix} 1 \\ 1 \end{bmatrix} \mathbf{z}_k, \quad (8)$$

Rekonstruktor je optimální, jelikož se vlastní čísla/póly matice  $(\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{F}$  nachází více vlevo, než vlastní čísla matice  $\mathbf{F}$ .

### 2.1.2 Kalmanův filtr

Nyní vezmeme v potaz stochastický charakter systému a formulujeme problém odhadu náhodného stavu pomocí Kalmanova filtru. Budeme využívat algoritmus prediktor - korektor, definujeme tedy následující vztahy, které byly odvozeny na přednášce:

1. Inicializace

$$\hat{\mathbf{x}}_0 = \bar{\mathbf{x}}_0 \quad (9)$$

$$\mathbf{P}_0 = \mathbf{P}_{\mathbf{x}_0} \quad (10)$$

2. Predikce (časový krok)

$$\hat{\mathbf{x}}'_{k+1} = \mathbf{F}\hat{\mathbf{x}}_k \quad (11)$$

$$\mathbf{P}'_{k+1} = \mathbf{F}\mathbf{P}_k\mathbf{F}^T + \mathbf{G}\mathbf{Q}\mathbf{G}^T \quad (12)$$

3. Korekce (začlenění měření/filtrace)

$$\mathbf{K}_{k+1} = \mathbf{P}'_{k+1}\mathbf{H}_{k+1}^T(\mathbf{H}_{k+1}\mathbf{P}'_{k+1}\mathbf{H}_{k+1}^T + \mathbf{R}_{k+1})^{-1} \quad (13)$$

$$\mathbf{P}_{k+1} = (\mathbf{I} - \mathbf{K}_{k+1}\mathbf{H}_{k+1})\mathbf{P}'_{k+1}(\mathbf{I} - \mathbf{K}_{k+1}\mathbf{H}_{k+1})^T + \mathbf{K}_{k+1}\mathbf{R}_{k+1}\mathbf{K}_{k+1}^T \quad (14)$$

$$\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}'_{k+1} + \mathbf{K}_{k+1}(\mathbf{z}_{k+1} - \mathbf{H}_{k+1}\hat{\mathbf{x}}'_{k+1}) \quad (15)$$

### 2.1.3 Ustálený Kalmanův filtr

Jedná se o stejný typ filtru jako v předchozím případě. Výjimku tvoří pouze hodnota zisku  $\mathbf{K}_{k+1}$ , která je v tomto případě konstantní. Hodnotu této konstanty lze určit jako tzv. ustálený Kalmanův zisk, který je definován pomocí následujícího vztahu:

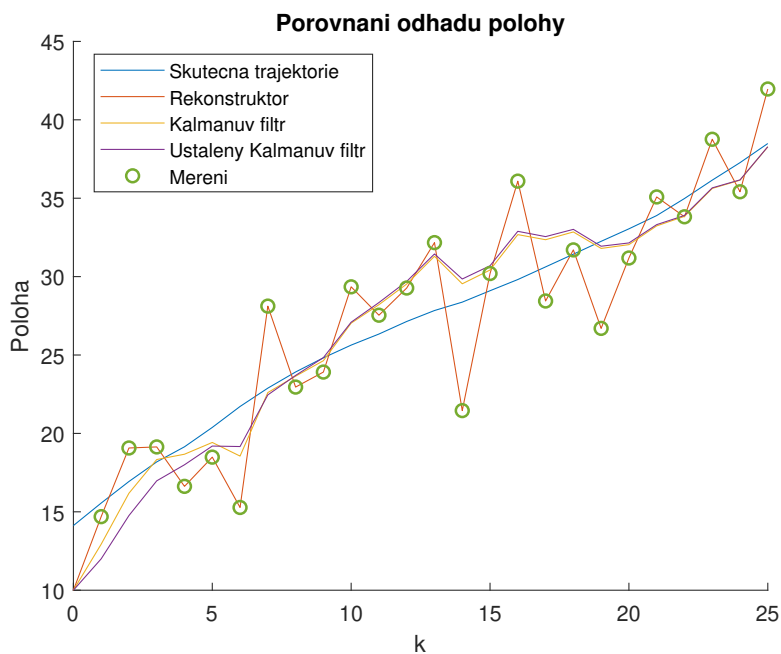
$$\mathbf{K}_\infty = \lim_{k \rightarrow \infty} \mathbf{K}_{k+1} \quad (16)$$

Hodnotu  $\mathbf{K}_\infty$  jsme vypočetli numericky s využitím vztahů (12), (13) a (14). Dostali jsme tento výsledek:

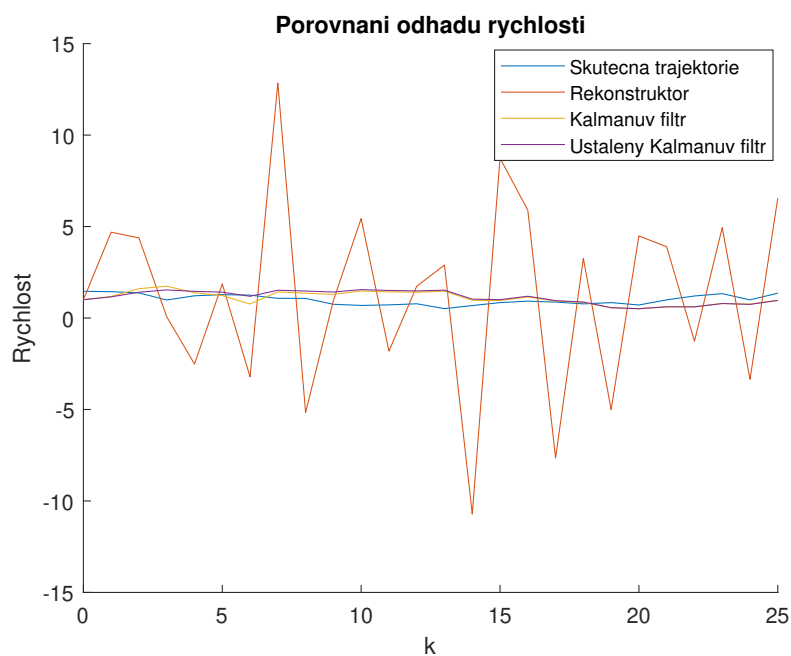
$$\mathbf{K}_\infty = \begin{bmatrix} 0.2711 \\ 0.0427 \end{bmatrix} \quad (17)$$

## 2.2 Úkol (ii)

V tomto úkolu jsme nejprve vykreslili první trajektorii stavu a porovnali ji s příslušnými filtračními odhady a měřeními.




Obrázek 1: Porovnání první trajektorie polohy a příslušných filtračních odhadů.




Obrázek 2: Porovnání první trajektorie rychlosti a příslušných filtračních odhadů.

Dále jsme vykreslili chyby filtračních odhadů polohy a rychlosti.



Obrázek 3: Porovnání chyb odhadu polohy příslušných filtračních odhadů.




Obrázek 4: Porovnání chyb odhadu rychlosti příslušných filtračních odhadů.

Jelikož generujeme náhodně všechny trajektorie pro  $k = 0, 1, \dots, 25$ , tak z pohledu první trajektorie nemohu říci nic.

### 2.3 Úkol (iii)

Cílem tohoto úkolu bylo analyzovat inovační posloupnost u případů (b) a (c). Zdefinujme inovační posloupnost pomocí následujícího vztahu:

$$\tilde{z}_k = z_k - E[z_k | z_{k-1}] = z_k - \mathbf{H} \hat{\mathbf{x}}'_k \quad (18)$$



Obrázek 5: Porovnání odhadů středních hodnot inovací. Lze si povšimnout, že odhady středních hodnot inovací nabývají hodnot kolem nuly, což splňuje předpoklad, že inovace, v obecném případě, je bílý proces nulovou střední hodnotou.

Dále byla vytvořeny dvě tabulky sloužící pro porovnání hodnot odhadů variancí a kovariancí inovací Kalmanových filtrů pro předem definované časové okamžiky  $k = 0, 1, 5$  a  $25$ .

cov $[\tilde{z}_k, \tilde{z}_n]$	Kalmanův filtr			
	k = 0	k = 1	k = 5	k = 25
n = 0	18.9227	9.4837	-1.4297	0.0641
n = 1	9.4837	21.2728	-0.7197	-0.1242
n = 5	-1.4297	-0.7197	16.6134	-0.8226
n = 25	0.0641	-0.1242	-0.8226	13.7480

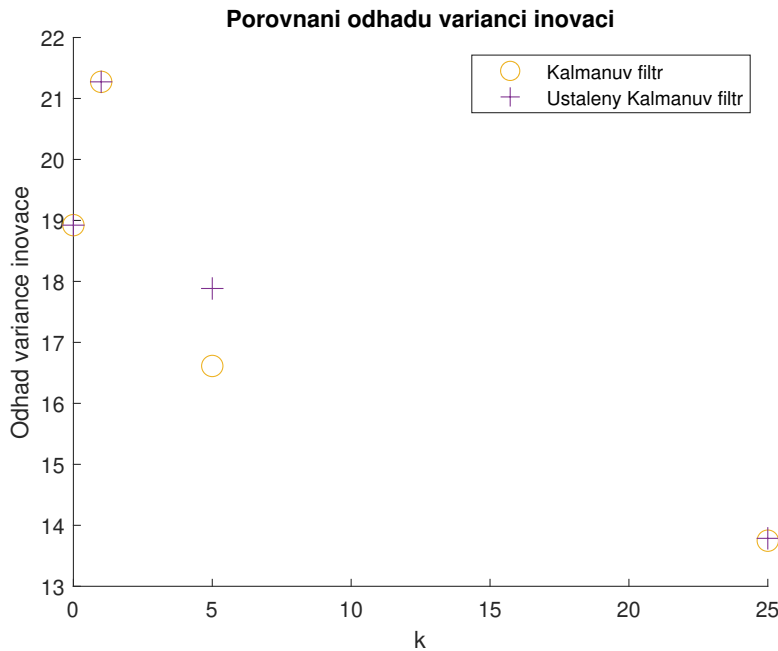
Tabulka 1: Tabulka obsahující hodnoty kovariancí (variancí) inovací Kalmanova filtru pro vybrané časy  $k$ .



$\text{cov}[\tilde{z}_k, \tilde{z}_n]$	Ustálený Kalmanův filtr			
	$k = 0$	$k = 1$	$k = 5$	$k = 25$
$n = 0$	18.9227	9.4837	0.2065	0.0623
$n = 1$	9.4837	21.2728	0.7865	-0.1743
$n = 5$	0.2065	0.7865	17.8841	-1.1523
$n = 25$	0.0623	-0.1743	-1.1523	13.7866

Tabulka 2: Tabulka obsahující hodnoty kovariancí (variancí) inovací ustáleného Kalmanova filtru pro vybrané časy  $k$ .

Variance inovací obou Kalmanových filtrů jsou rovny prvkům na hlavních diagonálách vytvořených tabulek. Hodnoty variancí obou filtrů jsme zanesli do následujícího grafu:



Obrázek 6: Porovnání variancí inovací Kalmanova filtru a Kalmanova ustáleného filtru.

Z obrázku (6) a tabulek (1) (2) je patrné, že hodnoty variancí v časových okamžicích  $k = 0$  a  $k = 1$  jsou ekvivalentní pro oba filtry. Je to dáno tím, že v obou případech uvažujeme neznalost měření v prvním okamžiku, kvůli čemuž se shodují počáteční prediktivní odhady. V čase  $k = 5$  dojde k rozdílu mezi hodnotami variancí, hodnota variance Kalmanova filtru je menší než hodnota variance ustáleného Kalmanova filtru. S přibývajícím časem se hodnoty variancí budou opět shodovat, což je způsobeno vzájemnou konvergencí mezi oběma filtry. Důkazem je hodnota variance Kalmanova i ustáleného Kalmanova filtru v čase  $k = 25$ .

## 2.4 Úkol (iv)

V tomto úkolu bylo cílem vyhodnotit kvalitu odhadů z pohledu střední kvadratické chyby (MSE). Střední kvadratická chyba je definována následovně:

$$\mathbb{E}[(\mathbf{x}_{k+1} - \hat{\mathbf{x}})^T(\mathbf{x}_{k+1} - \hat{\mathbf{x}})] = \mathbb{E}[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}] \quad (19)$$

### 2.4.1 Optimální deterministický rekonstruktor stavu

Nejprve zopakujme obecný vztah pro deterministický rekonstruktor:

$$\hat{\mathbf{x}}_{k+1} = (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{F}\hat{\mathbf{x}}_k + \mathbf{K}\mathbf{z}_{k+1}, \quad (20)$$

Rovnici (20) upravíme do následujícího tvaru:

$$\hat{\mathbf{x}}_{k+1} = (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\hat{\mathbf{x}}_k + \mathbf{K}\mathbf{H}\mathbf{F}\mathbf{x}_k, \quad (21)$$

Nyní vypočteme estimační chybu  $\tilde{\mathbf{x}}_k$ , která je definována následovně:

$$\tilde{\mathbf{x}}_{k+1} = \mathbf{x}_{k+1} - \hat{\mathbf{x}}_{k+1} \quad (22)$$

Dosadíme do rovnice (22), dostaneme:

$$\begin{aligned} \tilde{\mathbf{x}}_{k+1} &= \underbrace{\mathbf{F}\mathbf{x}_k + \mathbf{w}_k}_{\mathbf{x}_{k+1}} - \underbrace{[(\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\hat{\mathbf{x}}_k + \mathbf{K}\mathbf{H}\mathbf{F}\mathbf{x}_k]}_{\hat{\mathbf{x}}_{k+1}} = \\ &= \mathbf{F}\mathbf{x}_k + \mathbf{w}_k - (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\hat{\mathbf{x}}_k - \mathbf{K}\mathbf{H}\mathbf{F}\mathbf{x}_k = \\ &= \mathbf{F}\mathbf{x}_k - \mathbf{K}\mathbf{H}\mathbf{F}\mathbf{x}_k - (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\hat{\mathbf{x}}_k + \mathbf{w}_k = \\ &= (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\mathbf{x}_k - (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\hat{\mathbf{x}}_k + \mathbf{w}_k = \\ &= (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\tilde{\mathbf{x}}_k + \mathbf{w}_k - \mathbf{K}\mathbf{H}\mathbf{w}_k + (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{w}_k - \mathbf{K}\mathbf{v}_{k+1} = \\ &= (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\tilde{\mathbf{x}}_k + (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{w}_{k+1} - \mathbf{K}\mathbf{v}_{k+1} \end{aligned} \quad (23)$$

Dosadíme výslednou rovnici (23) do rovnice (19), čímž dostaneme vztah pro výpočet střední kvadratické chyby deterministického rekonstruktoru:

$$\mathbb{E}[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}] = (\mathbf{F} - \mathbf{K}\mathbf{H}\mathbf{F})\mathbb{E}[\tilde{\mathbf{x}}_k^T \tilde{\mathbf{x}}_k](\mathbf{F}^T - \mathbf{F}^T \mathbf{H}^T \mathbf{K}^T) + (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{Q}(\mathbf{I} - \mathbf{H}^T \mathbf{K}^T) + \mathbf{K}\mathbf{R}\mathbf{K}^T \quad (24)$$

Pro tento algoritmus je třeba stanovit počáteční podmínku:

$$\mathbb{E}[\tilde{\mathbf{x}}_0^T \tilde{\mathbf{x}}_0] = \text{var}[\mathbf{x}_0] = \mathbf{P}_{\mathbf{x}_0} = \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix} \quad (25)$$

### 2.4.2 Kalmanův filtr

Vztah pro výpočet střední kvadratické chyby Kalmanova filtru je totožný se vztahem pro výpočet kovarianční matice chyby po začlenění měření. Pouze místo apriorní kovarianční matice chyby  $\mathbf{P}_k$  dosadíme  $\mathbb{E}[\tilde{\mathbf{x}}_k^T \tilde{\mathbf{x}}_k]$ . Dostaneme tedy následující rovnici:

$$\mathbb{E}[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}] = \left[ (\mathbf{F}\mathbb{E}[\tilde{\mathbf{x}}_k^T \tilde{\mathbf{x}}_k]\mathbf{F}^T + \mathbf{Q})^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \right]^{-1} \quad (26)$$

Počáteční podmínka bude opět:

$$\mathbb{E}[\tilde{\mathbf{x}}_0^T \tilde{\mathbf{x}}_0] = \text{var}[\mathbf{x}_0] = \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix} \quad (27)$$

### 2.4.3 Ustálený Kalmanův filtr

I v případě ustáleného Kalmanova filtru je vztah pro výpočet střední kvadratické chyby totožný se vztahem pro výpočet kovarianční matice chyby. V tomto případě však využijeme Josephovu formu. Dostaneme tedy:

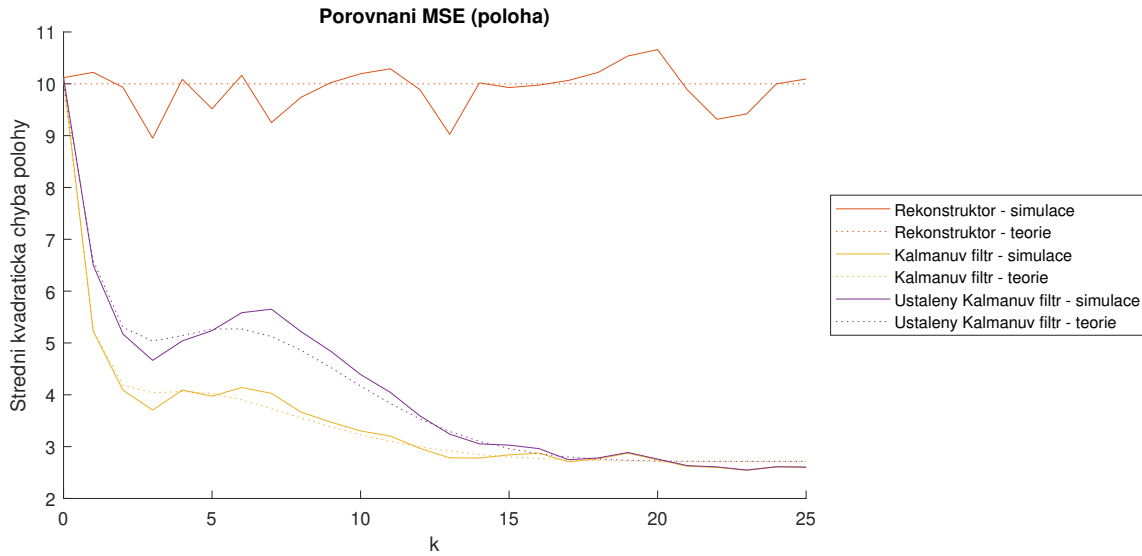
$$E[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}] = (\mathbf{I} - \mathbf{K}\mathbf{H})(\mathbf{F}E[\tilde{\mathbf{x}}_k^T \tilde{\mathbf{x}}_k]\mathbf{F}^T + \mathbf{Q})(\mathbf{I} - \mathbf{K}\mathbf{H})^T + \mathbf{K}\mathbf{R}\mathbf{K}^T \quad (28)$$

Počáteční podmínku opět volíme:


$$E[\tilde{\mathbf{x}}_0^T \tilde{\mathbf{x}}_0] = \text{var}[\mathbf{x}_0] = \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix} \quad (29)$$

### 2.4.4 Vykreslení

V této části jsme vykreslili simulačně získané střední hodnoty středních kvadratických chyb všech filtračních odhadů v závislosti na čase. Nejprve jsme vykreslili střední kvadratické chyby pro polohu a následně pro rychlost. Hodnoty středních kvadratických chyb *poloh* odpovídaly prvku na pozici (1,1) v příslušných maticích  $E[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}]$  o velikosti  $2 \times 2$ . Naopak hodnoty středních kvadratických chyb *rychlostí* odpovídaly prvku na pozici (2,2).



Obrázek 7: Porovnání středních kvadratických chyb polohy.

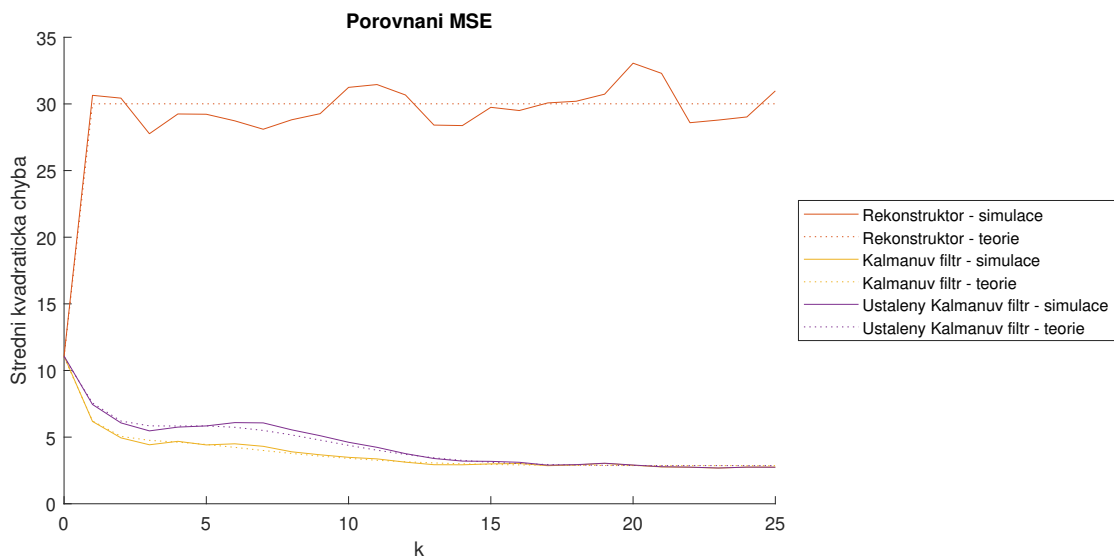


Obrázek 8: Porovnání středních kvadratických chyb rychlosti.

Pro střední kvadratickou chybu  $E[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}]$  platí, že je rovna stopě příslušné kovarianční matice. Platí tedy:

$$E[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}] = \text{tr}(E[\tilde{\mathbf{x}}_{k+1}^T \tilde{\mathbf{x}}_{k+1}]), \quad (30)$$

kde  $\text{tr}()$  značí součet všech prvků na hlavní diagonále (= stopa matice).



Obrázek 9: Porovnání středních kvadratických chyb rychlosti.

Z pohledu MSE se jako nejlepší algoritmus jeví Kalmanův filtr (c), následovaný ustáleným Kalmanovým filtrem (b). Naopak nejhorším algoritmem, který poskytuje největší chybu, je optimální deterministický rekonstruktor (a), jelikož nebere v potaz informace týkající se přítomných šumů.

### 3 Závěr

Hlavním cílem této semestrální práce bylo rekurzivně odhadovat polohu a rychlost objektu. Pro rekurzivní odhad jsme nejprve využili optimální deterministický rekonstruktor a následně pak Kalmanův a Kalmanův ustálený filtr. Následně jsme vykreslili první trajektorii stavu a porovnali ji s příslušnými filtračními měřeními. Dále jsme vykreslili chyby filtračních odhadů. V dalším úkolu jsme se zabývali analýzou inovační posloupnosti u Kalmanova a Kalmanova ustáleného filtru. Porovnali jsme odhady středních hodnot inovací ve všech časech a odhady variancí inovací pro  $k = 0, 1, 5, 25$ . V závěru jsme se věnovali vyhodnocení kvality odhadů z pohledu střední kvadratické chyby (MSE). Odhadli jsme střední hodnoty kvadratických chyb všech filtračních odhadů v závislosti na čase a získané křivky porovnali s teoretickými hodnotami.

## Seznam obrázků

1	Porovnání první trajektorie polohy a příslušných filtračních odhadů. . . . .	6
2	Porovnání první trajektorie rychlosti a příslušných filtračních odhadů. . . . .	6
3	Porovnání chyb odhadu polohy příslušných filtračních odhadů. . . . .	7
4	Porovnání chyb odhadu rychlosti příslušných filtračních odhadů. . . . .	7
5	Porovnání odhadů středních hodnot inovací. Lze si povšimnout, že odhady středních hodnot inovací nabývají hodnot kolem nuly, což splňuje předpoklad, že inovace, v obecném případě, je bílý proces nulovou střední hodnotou. . . . .	8
6	Porovnání variancí inovací Kalmanova filtru a Kalmanova ustáleného filtru. . . . .	9
7	Porovnání středních kvadratických chyb polohy. . . . .	11
8	Porovnání středních kvadratických chyb rychlosti. . . . .	12
9	Porovnání středních kvadratických chyb rychlosti. . . . .	12